TRƯỜNG ĐẠI HỌC CÔNG NGHỆ THÔNG TIN VÀ TRUYỀN THÔNG

KHOA CÔNG NGHỆ THÔNG TIN

BÁO CÁO TIỂU LUẬN

HỌC PHẦN: HỌC MÁY

ĐỀ TÀI:

PHÂN NHÓM CỔ PHIẾU THEO MỨC ĐỘ ĐỒNG BIẾN ĐỘNG GIÁ PHỤC VỤ ĐA DẠNG HÓA DANH MỤC ĐẦU TƯ

Giảng viên hướng dẫn: Thầy Nguyễn Tuấn Anh

Lớp học phần: CNTT K22G

Nhóm thực hiện: Nhóm 1

Trần Phương Đoàn – DTC235200199

Hà Văn Dũng – DTC235200121

Thái Nguyên, tháng 11 năm 2026

NHẬN XÉT CỦA GIẢNG VIÊN

1. Về hình thức và bố cục báo cáo:

. . . . . .

. . . . . .

. . . . . .

2. Về nội dung và kết quả thực hiện qua các mốc kiểm tra:

. . . . . .

. . . . . .

. . . . . .

. . . . . .

. . . . . .

3. Về tinh thần, thái độ làm việc của nhóm:

. . . . . .

. . . . . .

. . . . . .

4. Điểm đánh giá:

STT	Họ và tên sinh viên	Điểm số	Điểm chữ
1	Trần Phương Đoàn		
2	Hà Văn Dũng		

Thái Nguyên, ngày ... tháng ... năm ...

Giảng viên

(Ký và ghi rõ họ tên)

Thầy Nguyễn Tuấn Anh

LỜI CAM ĐOAN

Chúng em xin cam đoan báo cáo tiểu luận "*PHÂN NHÓM CỔ PHIẾU THEO MỨC ĐỘ ĐỒNG BIẾN ĐỘNG GIÁ PHỤC VỤ ĐA DẠNG HÓA DANH MỤC ĐẦU TƯ*" là kết quả nghiên cứu và thực nghiệm nghiêm túc của nhóm dưới sự định hướng chuyên môn của Thầy Nguyễn Tuấn Anh. Toàn bộ chuỗi dữ liệu giá cổ phiếu, các quyết định tiền xử lý dữ liệu, các phép biến đổi mêtric khoảng cách, kết quả so sánh đối chứng giữa các thuật toán phân cụm, đánh giá độ ổn định liên pha qua 3 chu kỳ thị trường và đối chiếu phân ngành ICB trình bày trong báo cáo đều được trích xuất hoàn toàn trung thực từ hệ thống 8 sổ tay Jupyter Notebook thực nghiệm của nhóm; tất cả các kết quả thực nghiệm đều có khả năng chạy lại và tái hiện độc lập 100%.

Khai báo sử dụng công cụ AI tạo sinh: Trong quá trình thực hiện dự án, nhóm có sử dụng các mô hình ngôn ngữ lớn (Gemini, Claude) với vai trò trợ lý hỗ trợ kỹ thuật: tra cứu tài liệu học thuật về lý thuyết ma trận ngẫu nhiên (RMT) và phân cụm tài chính trên Google Scholar, hỗ trợ hoàn thiện cú pháp mã nguồn Python vẽ biểu đồ khoa học và kiểm tra lỗi định dạng văn bản LaTeX. Toàn bộ các phân tích thống kê, logic phát biểu bài toán, quy tắc điền khuyết chống rò rỉ dữ liệu, việc chứng minh toán học đẳng thức mặt cầu $\mathbb{S}^{T-1}$, phân tích lỗi các mẫu vùng ranh giới và nội dung báo cáo đều do các thành viên trong nhóm trực tiếp nghiên cứu, lập trình và chịu trách nhiệm giải trình.

Nếu phát hiện có bất kỳ sự sao chép trái phép hay gian lận học thuật nào, nhóm chúng em xin hoàn toàn chịu mọi hình thức kỷ luật trước giảng viên và nhà trường.

Thái Nguyên, ngày ... tháng 11 năm 2026

Nhóm sinh viên thực hiện

(Ký và ghi rõ họ tên)

Trần Phương Đoàn Hà Văn Dũng

LỜI CẢM ƠN

Nhóm chúng em xin bày tỏ lòng biết ơn sâu sắc và chân thành nhất tới **Thầy Nguyễn Tuấn Anh**, người đã tận tình hướng dẫn, trang bị những nền tảng lý thuyết vững chắc về bộ môn Học máy và trực tiếp định hướng cho nhóm tiếp cận một đề tài mang tính liên ngành cao giữa Trí tuệ nhân tạo và Tài chính định lượng (Quantitative Finance). Sự chỉ dẫn khoa học của thầy về tư duy nghiên cứu dựa trên bằng chứng thực nghiệm (Evidence-Based Research), việc so sánh đối chứng khách quan giữa các thuật toán, đo lường độ ổn định qua các chu kỳ thị trường và lật tẩy các bẫy điểm số ảo trong phân cụm đã giúp nhóm định hình rõ ràng phương pháp tiếp cận đúng đắn, xây dựng quy trình thực nghiệm chặt chẽ từ tiền xử lý, huấn luyện, đánh giá đối chứng đến kiểm định ổn định liên pha.

Nhóm cũng xin chân thành cảm ơn các thầy cô giáo trong Khoa Công nghệ Thông tin – Trường Đại học Công nghệ Thông tin và Truyền thông đã tạo điều kiện học tập thuận lợi, xây dựng chương trình đào tạo hiện đại giúp sinh viên có đủ kiến thức và kỹ năng thực hành để hoàn thành các giai đoạn của dự án.

Mặc dù nhóm đã nỗ lực hết mình để khảo sát, tiền xử lý và thiết lập mô hình học máy một cách khoa học nhất, song do thời gian và kiến thức còn hạn chế, báo cáo chắc chắn khó tránh khỏi những thiếu sót. Chúng em rất mong tiếp tục nhận được những ý kiến đóng góp, chỉ bảo quý báu của thầy để nhóm hoàn thiện tốt hơn nữa trong giai đoạn ứng dụng đa dạng hóa danh mục đầu tư và kiểm thử lịch sử ngoài mẫu (Backtesting) ở Bài kiểm tra số 3 tiếp theo.

Nhóm sinh viên thực hiện

BẢNG PHÂN CÔNG NHIỆM VỤ

STT	Họ và tên	Nhiệm vụ phụ trách trong Mốc 1 & Mốc 2	Mức độ hoàn thành
1	Trần Phương Đoàn (DTC235200199)	– Thu thập dữ liệu thô 100 mã VN100 qua API (nb01) – Lọc mã thiếu, khử 68 ngày nghỉ lễ sàn HOSE, điền khuyết Forward-fill (nb02) – Tính toán ma trận Pearson và khoảng cách Mantegna, kiểm định bất đẳng thức tam giác (nb04) – Thực nghiệm 4 tiêu chí liên kết, đo CCC, quét $K \in [3, 15]$ và chốt $K^* = 10$ (nb07) – Đánh giá độ ổn định liên pha 3 chu kỳ (ARI) và đối chiếu 11 ngành ICB (nb08) – Viết nội dung Chương 2, Chương 4, Chương 5	100%
2	Hà Văn Dũng (DTC235200121)	– Trích chọn lợi suất logarit, kiểm định Jarque-Bera, Fat-tails (nb03) – Thiết kế phân chia Train/Test theo chu kỳ dựa trên RMT ($Q = 7.54$) (nb05) – Thực nghiệm đối chứng các thuật toán phân cụm (K-Means, Bisecting, DIANA, Agglomerative) (nb06) – Xây dựng 2 Baseline PCA 5D / PCA 45D, kiểm định Block Sub-sampling ($B = 30$) và phân tích lỗi mẫu ranh giới (nb07) – Viết nội dung Chương 1, Chương 3 và các Phụ lục	100%

MỤC LỤC

LỜI CAM ĐOAN . . . . . **ii**

LỜI CẢM ƠN . . . . . **iii**

BẢNG PHÂN CÔNG NHIỆM VỤ . . . . . **iv**

DANH MỤC HÌNH ẢNH . . . . . **viii**

DANH MỤC BẢNG . . . . . **x**

DANH MỤC TỪ VIẾT TẮT . . . . . **xi**

MỞ ĐẦU **1**

Chương 1. Xác định bài toán học máy và cơ sở lý thuyết **5**

1.1. Bối cảnh thực tiễn và bài toán đa dạng hóa danh mục 5

1.2. Phát biểu bài toán học máy theo Mitchell 6

1.3. Mục tiêu và tiêu chí thành công 7

1.4. Cơ sở lý thuyết về không gian khoảng cách trong dữ liệu tài chính 9

1.4.1. Nghịch lý của khoảng cách Euclid trên chuỗi lợi suất 9

1.4.2. Khoảng cách mêtric Mantegna 10

1.5. Lý giải phương pháp phân chia dữ liệu và chỉ số đánh giá 11

1.5.1. Chiến lược phân chia Hold-out theo thời gian (Chronological Split) . 11

1.5.2. Cơ sở Lý thuyết Ma trận Ngẫu nhiên (Random Matrix Theory – RMT) 12

Chương 2. Thu thập và khảo sát thống kê dữ liệu **13**

2.1. Nguồn thu thập và điều kiện sử dụng dữ liệu. 13

2.2. Không gian mẫu và từ điển dữ liệu. 13

2.3. Khảo sát thống kê mô tả chuỗi thời gian giá 14

2.4. Phân tích phân bố lợi suất và kiểm định hiện tượng đuôi béo (Fat-tails). . . 15

2.5. Khảo sát không gian Lợi suất – Rủi ro (Risk-Return Trade-off) 17

2.6. Phân tích ma trận tương quan và quan hệ giữa các cổ phiếu 18

Chương 3. Tiền xử lý dữ liệu và chuẩn bị cho mô hình 21
3.1. Phát hiện và định lượng các vấn đề chất lượng dữ liệu 21
3.2. Phương pháp và lý do xử lý chất lượng dữ liệu 22
3.3. So sánh đối chiếu dữ liệu trước và sau tiền xử lý 23
3.4. Chiến lược phân chia tập Train / Test theo chu kỳ thị trường 24
3.4.1. So sánh phản biện các phương pháp phân chia dữ liệu 24
3.4.2. Chi tiết phân chia và quy mô các tập dữ liệu 26
3.5. Nguyên tắc ngăn chặn rò rỉ dữ liệu (Information Leakage) 27
Chương 4. Thực nghiệm phân cụm và so sánh đối chứng mô hình 28
4.1. Lựa chọn thuật toán: Đối chứng khách quan các thuật toán phân cụm 28
4.1.1. Bằng chứng định lượng so sánh đối chứng các thuật toán phân cụm . 28
4.1.2. Biện luận lý thuyết và bản chất vi mô thị trường tài chính 30
4.2. Thiết lập hai mô hình cơ sở đối chứng (Baseline Models) 31
4.3. Quy trình huấn luyện và Cài đặt mô hình bằng Python 31
4.4. Thực nghiệm bốn tiêu chí liên kết (Linkages) và Chứng minh đẳng thức mặt cầu 32
4.4.1. Hệ số tương quan Cophenetic (CCC) và Bẫy điểm số ảo 33
4.4.2. Chứng minh toán học đẳng thức mặt cầu $\mathbb{S}^{T-1}$ bảo đảm tính hợp lệ của Ward 34
4.5. Quét thực nghiệm số cụm $K \in [3, 15]$ và Ma trận đa tiêu chí chốt $K^* = 10$. 35
4.5.1. Thiết lập Bộ lọc khả thi danh mục đầu tư (Portfolio Feasibility Filter) 35
4.5.2. Hàm điểm tổng hợp đa mục tiêu (Composite Score) 35
4.6. Kiểm định độ ổn định nội tại bằng Block Sub-sampling ($B = 30$) và So sánh với Baseline 37
4.6.1. Thiết kế thí nghiệm Block Sub-sampling 37
4.6.2. Nhận định kết quả so sánh với Baseline 38
4.7. Phân tích kết quả dự đoán và Mẫu vùng ranh giới (Error Analysis) 39

Chương 5. Đánh giá độ ổn định liên pha và đối chiếu phân ngành ICB 42

5.1. Phương pháp phân định ba pha thị trường và Ma trận tương đồng ARI liên pha 42

5.1.1. Ma trận Adjusted Rand Index (ARI) giữa các chu kỳ độc lập 43

5.1.2. Biện luận kinh tế cho mức độ ổn định $\overline{\text{ARI}} \approx 0.32$ 44

5.2. Đối chiếu định lượng với 11 phân ngành chuẩn ICB cấp 1 44

5.3. Bóc tách ba nhóm hình thái cụm tài chính đặc thù 46

5.3.1. Hình thái 1: Các cụm thuần khiết 100% ngành (Domain Confirmation) 46

5.3.2. Cụm liên ngành dòng tiền High-Beta 46

5.3.3. Hình thái 3: Nhóm phòng thủ, vốn hóa lớn và điều tiết chỉ số (Defensive Regulators) 47

KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN 48

BẢNG TỰ ĐÁNH GIÁ THEO TIÊU CHÍ CHẤM 50

TÀI LIỆU THAM KHẢO 54

Phụ lục A. Hướng dẫn môi trường và thực thi các Notebook thực nghiệm . . . 55

A.1. Yêu cầu môi trường phần mềm 55

A.2. Cấu trúc hệ sinh thái 8 Notebook phục vụ kiểm tra vấn đáp tại chỗ (Tiêu chí 10) 55

A.3. Hướng dẫn chạy lại toàn bộ pipeline thực nghiệm 56

Phụ lục B. Nhật ký đóng góp của các thành viên trong nhóm 57

DANH MỤC HÌNH ẢNH

Hình 1.1. Quy trình tổng thể dự án học máy (các khối tô màu xanh đại diện cho các bước đã hoàn thành) 6

Hình 1.2. Minh họa nghịch lý khoảng cách Euclid so với tương quan Pearson trên chuỗi tài chính 9

Hình 1.3. Phép biến đổi Mantegna từ hệ số tương quan ρ sang khoảng cách mêtric d 11

Hình 2.1. Diễn biến giá đóng cửa điều chỉnh chuẩn hóa (cơ sở 100) của 98 cổ phiếu VN100 15

Hình 2.2. Phân phối tần suất lợi suất logarit và biểu đồ Q-Q Plot toàn thị trường VN100 16

Hình 2.3. Không gian Lợi suất kỳ vọng – Rủi ro biến động của 98 cổ phiếu theo nhóm ngành ICB 17

Hình 2.4. Bản đồ nhiệt ma trận tương quan Pearson tập Train (98×98 cổ phiếu) . . 18

Hình 2.5. Bản đồ nhiệt ma trận khoảng cách Mantegna tập Train (98×98 cổ phiếu) 20

Hình 3.1. Chiến lược phân chia dữ liệu Train (2022–2024) và Test (2025–2026) theo chu kỳ thị trường 26

Hình 4.1. So sánh trực quan giữa mô hình phân hoạch phẳng K-Means và mô hình phân cấp gộp Bottom-Up trên không gian dữ liệu tập Train. 30

Hình 4.2. Cây phân cấp Dendrogram của 98 cổ phiếu VN100 trên tập Train ứng với 4 tiêu chí liên kết 33

Hình 4.3. Diễn biến các chỉ số đánh giá khi quét số cụm $K \in [3, 15]$ cho 4 tiêu chí liên kết 37

Hình 4.4. So sánh phân bố các chỉ số đánh giá giữa Mô hình đề xuất và hai biến thể Baseline qua 30 lần Block Sub-sampling 38

Hình 4.5. Bản đồ nhiệt Clustermap sắp xếp theo 10 cụm tối ưu 39

Hình 4.6. Chiếu trực quan 10 cụm tối ưu lên không gian 2D PCA 39

Hình 5.1. Biểu đồ nhiệt ma trận Adjusted Rand Index (ARI) đánh giá độ ổn định phân cụm qua 3 pha thị trường 43

Hình 5.2. Bảng chéo (Crosstab Matrix) trực quan hóa phân bố của 10 cụm máy học theo 11 nhóm ngành ICB 45

DANH MỤC BẢNG

Bảng 1.1. Bảng chuyển đổi mục tiêu thực tế thành chỉ số học máy và tiêu chí thành công. 8

Bảng 2.1. Từ điển dữ liệu các đặc trưng tài chính trích chọn từ chuỗi lợi suất 14

Bảng 3.1. Bảng định lượng các vấn đề chất lượng dữ liệu phát hiện trong tập dữ liệu thô. 22

Bảng 3.2. So sánh các chỉ số chất lượng dữ liệu trước và sau quy trình tiền xử lý. . 24

Bảng 3.3. So sánh phản biện các phương pháp phân chia tập dữ liệu trong bài toán học máy tài chính 25

Bảng 4.1. So sánh đối chứng định lượng giữa các thuật toán phân cụm trên tập Train 29

Bảng 4.2. Kết quả quét thực nghiệm $K \in [5, 15]$ cho Ward Linkage trên tập Train . 36

Bảng 4.3. So sánh định lượng giữa Mô hình đề xuất (Ward $K^* = 10$) và 2 Baseline qua 30 lần Block Sub-sampling 38

Bảng 4.4. Danh sách 6 cổ phiếu vùng ranh giới có hệ số Silhouette âm và phân tích nguyên nhân kinh tế 40

Bảng 5.1. Ma trận chỉ số Adjusted Rand Index (ARI) giữa 3 pha thị trường và Toàn kỳ Train 43

Bảng 5.2. Các chỉ số đối sánh định lượng giữa 10 cụm máy học và 11 phân ngành chuẩn ICB cấp 1 45

Bảng 5.3. Bảng tự đánh giá kết quả thực hiện Mốc 1 (Tuần 4) 50

Bảng 5.4. Bảng tự đánh giá kết quả thực hiện Mốc 2 (Tuần 6) 51

Bảng B.1. Nhật ký công việc và đóng góp của các thành viên từ Tuần 1 đến Tuần 6 58

DANH MỤC TỪ VIẾT TẮT

STT	Viết tắt	Thuật ngữ đầy đủ và ý nghĩa
1	ARI	Adjusted Rand Index – Chỉ số Rand điều chỉnh (đo độ ổn định phân cụm)
2	CCC	Cophenetic Correlation Coefficient – Hệ số tương quan Cophenetic
3	CVaR	Conditional Value at Risk – Giá trị rủi ro có điều kiện
4	DIANA	Divisive Analysis – Thuật toán phân cấp chia dần từ trên xuống
5	EDA	Exploratory Data Analysis – Phân tích khám phá dữ liệu
6	ESS	Error Sum of Squares – Tổng bình phương sai số gia tăng (hàm mục tiêu Ward)
7	HOSE	Ho Chi Minh Stock Exchange – Sở Giao dịch Chứng khoán TP. Hồ Chí Minh
8	HRP	Hierarchical Risk Parity – Phương pháp cân bằng rủi ro phân cấp
9	ICB	Industry Classification Benchmark – Chuẩn phân ngành công nghiệp quốc tế
10	MDD	Maximum Drawdown – Mức sụt giảm vốn tối đa
11	ML	Machine Learning – Học máy
12	MPT	Modern Portfolio Theory – Lý thuyết danh mục đầu tư hiện đại Markowitz
13	NMI	Normalized Mutual Information – Thông tin tương hỗ chuẩn hóa
14	OOS	Out-of-Sample – Ngoài mẫu (tập kiểm thử độc lập)
15	PCA	Principal Component Analysis – Phân tích thành phần chính

STT	Viết tắt	Thuật ngữ đầy đủ và ý nghĩa (tiếp theo)
16	RMT	Random Matrix Theory – Lý thuyết ma trận ngẫu nhiên
17	UPGMA	Unweighted Pair Group Method with Arithmetic Mean (tiêu chí Average Linkage)
18	VaR	Value at Risk – Giá trị rủi ro danh mục
19	VN100	Chỉ số 100 cổ phiếu vốn hóa và thanh khoản hàng đầu thị trường Việt Nam

MỞ ĐẦU

1. Lý do chọn đề tài

Trong thị trường tài chính, đa dạng hóa danh mục đầu tư là nguyên lý cốt lõi giúp nhà đầu tư giảm thiểu rủi ro phi hệ thống (rủi ro riêng lẻ của từng doanh nghiệp) mà không làm suy giảm lợi suất kỳ vọng. Theo Lý thuyết Danh mục Đầu tư Hiện đại (Modern Portfolio Theory – MPT) của Harry Markowitz (1952), hiệu quả phân tán rủi ro phụ thuộc trực tiếp vào hệ số tương quan giữa các tài sản trong danh mục: khi nắm giữ các cổ phiếu có mức độ tương quan thấp hoặc biến động ngược chiều, phương sai tổng thể của danh mục sẽ giảm đáng kể.

Tuy nhiên, trong thực tế đầu tư, các phương pháp phân bổ tài sản truyền thống thường dựa vào phân loại ngành hành chính (như chuẩn phân ngành ICB, GICS) hoặc ước lượng ma trận hiệp phương sai trực tiếp trên quy mô lớn. Cách tiếp cận này bộc lộ hai nhược điểm nghiêm trọng:

1. *Tính chủ quan của phân loại ngành:* Hai cổ phiếu thuộc cùng một ngành danh nghĩa (ví dụ: nhóm Bất động sản) có thể có cấu trúc đòn bẩy tài chính và tính nhạy cảm dòng tiền rất khác nhau; ngược lại, các cổ phiếu thuộc hai ngành khác nhau (ví dụ: Thép và Bất động sản xây dựng) lại có thể đồng biến động giá rất mạnh do liên kết chuỗi cung ứng.
2. *Sự nhiễu loạn ma trận tương quan quy mô lớn:* Khi số lượng tài sản N lớn, việc tối ưu hóa danh mục theo Markowitz đòi hỏi nghịch đảo ma trận hiệp phương sai, dẫn đến sự bất ổn định số học và khuếch đại sai số ước lượng (hiện tượng Markowitz Curse).

Sự kết hợp giữa các thuật toán Học máy không giám sát (Unsupervised Machine Learning), cụ thể là các thuật toán phân cụm (Clustering), với các độ đo khoảng cách tài chính phi tuyến mở ra hướng tiếp cận ưu việt. Bằng cách phân nhóm cổ phiếu dựa trên chính mức độ đồng biến động giá lịch sử thực tế thay vì nhãn ngành chủ quan, mô hình học máy cho phép bóc tách cấu trúc vi mô của thị trường, tìm ra các nhóm cổ phiếu độc lập thực sự để phục vụ chiến lược đa dạng hóa danh mục đầu tư hiệu quả.

2. Mục tiêu và nhiệm vụ nghiên cứu

Báo cáo tập trung giải quyết toàn diện các yêu cầu về khảo sát bài toán, thu thập, tiền xử lý dữ liệu và thiết lập không gian mêtric cho mô hình học máy phục vụ phân nhóm cổ phiếu và đa dạng hóa danh mục:

- **Phát biểu chuẩn xác bài toán học máy:** Xác định rõ nhiệm vụ học máy không giám sát, đơn vị mẫu 98 mã VN100, đầu vào ma trận khoảng cách đồng biến động và đầu ra cấu trúc phân cụm; chuyển đổi mục tiêu tài chính sang các chỉ số định lượng đo lường được.
- **Thu thập và mô tả dữ liệu toàn diện:** Xây dựng đường ống thu thập tự động dữ liệu giá lịch sử của 100 cổ phiếu thành phần rổ VN100 giai đoạn 2022–2026; lập từ điển dữ liệu tài chính và metadata phân ngành ICB.
- **Khảo sát thống kê và phân tích cấu trúc dữ liệu:** Thực hiện phân tích khám phá dữ liệu (EDA), phân tích phân bố lợi suất logarit, kiểm định thống kê hiện tượng đuôi béo (Fat-tails) và phân tích không gian lợi suất – rủi ro.
- **Định lượng và xử lý triệt để các vấn đề chất lượng dữ liệu:** Phát hiện và loại bỏ các mã thiếu hụt dữ liệu niên yết lớn, chuẩn hóa lịch giao dịch sàn HOSE, điền khuyết bằng phương pháp Forward-fill bảo toàn tính nhân quả và loại bỏ hoàn toàn nguy cơ rò rỉ dữ liệu tương lai (Look-ahead bias).
- **Thiết lập không gian khoảng cách mêtric và phân chia Train/Test:** Phân tích nhược điểm của khoảng cách Euclid, chuyển đổi hệ số tương quan Pearson sang khoảng cách Mantegna thỏa mãn 4 tiên đề mêtric; phân tách ranh giới tập Train (2022–2024) và Test (2025–2026) theo chu kỳ thị trường dựa trên cơ sở Lý thuyết Ma trận Ngẫu nhiên (RMT).

3. Đối tượng và phạm vi nghiên cứu

- **Không gian mẫu nghiên cứu:** 100 cổ phiếu thuộc rổ chỉ số VN100 niêm yết trên Sở Giao dịch Chứng khoán TP. Hồ Chí Minh (HOSE), đại diện cho hơn 90% giá trị vốn hóa và 85% thanh khoản toàn thị trường chứng khoán Việt Nam.
- **Phạm vi thời gian:** Giai đoạn 5 năm từ ngày 01/01/2022 đến ngày 23/10/2026, trải qua đầy đủ các giai đoạn thị trường đặc thù: sụt giảm sâu (Downtrend 2022), phục hồi tích lũy (2023–2024) và phân hóa đi ngang (2025–2026).
- **Dữ liệu sử dụng:** Chuỗi giá đóng cửa điều chỉnh (adj_close) hàng ngày đã xử lý quyền chia cổ tức và phát hành thêm, cùng chuỗi lợi suất logarit liên tục.

4. Phương pháp thực hiện

Đề tài sử dụng ngôn ngữ lập trình Python 3.12 cùng các thư viện khoa học dữ liệu chuẩn mực (numpy, pandas, scipy, scikit-learn, matplotlib, seaborn). Toàn bộ quy trình thực nghiệm được cấu trúc hóa thành 5 sổ tay Jupyter Notebook độc lập, có khả năng thực thi tuần tự và kiểm chứng kết quả trực tiếp:

- 01_data_collection_prep.ipynb: Thu thập dữ liệu thô 100 mã VN100 và meta-data ngành.
- 02_data_preprocessing.ipynb: Lọc mã thiếu, khử ngày nghỉ lễ và điền khuyết Forward-fill.
- 03_feature_extraction_returns.ipynb: Trích chọn lợi suất logarit, kiểm định Jarque-Bera.
- 04_correlation_distance.ipynb: Xây dựng ma trận tương quan Pearson và khoảng cách Mantegna.
- 05_train_test_split.ipynb: Phân chia tập Train/Test theo thời gian và xuất bản ma trận huấn luyện.

5. Bố cục báo cáo

Nội dung báo cáo tính đến hết Mốc 2 được trình bày toàn diện trong 5 chương trọng tâm:

- **Chương 1. Xác định bài toán học máy và cơ sở lý thuyết:** Phát biểu bài toán theo Mitchell, bảng mục tiêu – chỉ số thành công, cơ sở mêtric Mantegna và phương pháp luận đánh giá chuỗi thời gian.
- **Chương 2. Thu thập và khảo sát thống kê dữ liệu:** Nguồn dữ liệu, từ điển 8 đặc trưng tài chính, phân tích đuôi béo lợi suất, không gian rủi ro – lợi suất và ma trận tương quan Pearson.
- **Chương 3. Tiền xử lý dữ liệu và chuẩn bị cho mô hình:** Xử lý dữ liệu khuyết bằng Forward-fill, lọc bỏ 68 ngày nghỉ lễ, chiến lược chia Train/Test theo chu kỳ và chống rò rỉ dữ liệu.
- **Chương 4. Thực nghiệm phân cụm và so sánh đối chứng mô hình:** Đối chứng các thuật toán phân cụm, xây dựng 2 mô hình cơ sở (Baseline PCA 5D/45D), thực nghiệm 4 tiêu chí liên kết, chứng minh đẳng thức mặt cầu $\mathbb{S}^{T-1}$, quét thực nghiệm $K \in [3, 15]$ chốt $K^* = 10$, kiểm định Block Sub-sampling ($B = 30$) và phân tích lỗi mẫu ranh giới.

- **Chương 5. Đánh giá độ ổn định liên pha và đối chiếu phân ngành ICB:** Đánh giá độ ổn định liên pha qua 3 chu kỳ (2022 Downtrend, 2023 Tích lũy, 2024 Phục hồi) bằng ARI, đối chiếu định lượng với 11 ngành ICB cấp 1 ($NMI = 0.5339$, Purity=60.20%) và bóc tách 3 hình thái cụm tài chính đặc thù.

Cuối báo cáo là phần Kết luận, Bảng tự đánh giá theo 10 tiêu chí chấm điểm của giảng viên, Danh mục tài liệu tham khảo và các Phụ lục hướng dẫn thực nghiệm.

CHƯƠNG 1

XÁC ĐỊNH BÀI TOÁN HỌC MÁY VÀ CƠ SỞ LÝ THUYẾT

1.1. Bối cảnh thực tiễn và bài toán đa dạng hóa danh mục

Trong quản lý danh mục đầu tư theo lý thuyết hiện đại của Harry Markowitz [1], phương sai của một danh mục gồm N tài sản với các tỷ trọng phân bổ $w = [w_1, \ldots, w_N]^T$ ($\sum_{i=1}^{N} w_i = 1$) được xác định bởi công thức:

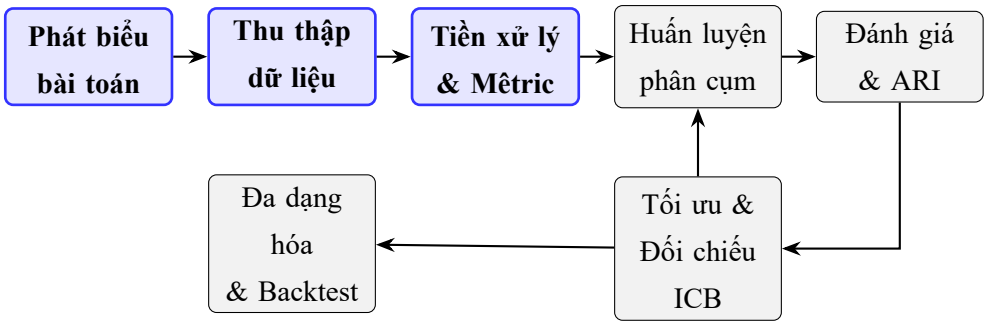
$$\sigma_p^2 = \sum_{i=1}^{N} w_i^2 \sigma_i^2 + 2 \sum_{i=1}^{N} \sum_{j<i} w_i w_j \sigma_i \sigma_j \rho_{ij} \tag{1.1}$$

Trong đó σ_i, σ_j là độ lệch chuẩn (đo lường rủi ro biến động) của tài sản i và j, còn $\rho_{ij} \in [-1, 1]$ là hệ số tương quan giữa hai chuỗi lợi suất.

Từ phương trình (1.1), có thể thấy số lượng thành phần hiệp phương sai tăng theo cấp số bậc hai $N(N-1)/2$. Khi các tài sản có hệ số tương quan đồng pha mạnh ($\rho_{ij} \to 1$), rủi ro của danh mục xấp xỉ bằng bình quân gia quyền rủi ro các tài sản đơn lẻ, triệt tiêu hoàn toàn lợi ích của việc đa dạng hóa. Ngược lại, nếu nhóm các tài sản được lựa chọn có hệ số tương quan thấp ($\rho_{ij} \to 0$) hoặc ngược pha ($\rho_{ij} < 0$), thành phần thứ hai trong phương trình (1.1) sẽ tiệm cận về 0 hoặc mang giá trị âm, giúp giảm mạnh độ biến động tổng thể σ_p của danh mục.

Do đó, vấn đề cốt lõi của bài toán đầu tư thực tế là: *Làm thế nào để phân nhóm tự động hàng trăm cổ phiếu trên thị trường thành các cụm có tính chất đồng biến động cao trong nội bộ cụm, nhưng hoàn toàn độc lập hoặc phân kỳ giữa các cụm khác nhau?* Giải quyết được bài toán này sẽ cung cấp cơ sở dữ liệu định lượng vững chắc để nhà đầu tư chỉ cần chọn ra các đại diện ưu tú từ các cụm khác nhau, thiết lập một danh mục đa dạng hóa tối ưu mà không bị lệ thuộc vào định kiến chủ quan của nhãn ngành truyền thống.

Quy trình thực hiện tổng quát của đề tài được mô tả trực quan trong Hình 1.1.



Hình 1.1. Quy trình tổng thể dự án học máy (các khối tô màu xanh đại diện cho các bước đã hoàn thành)

1.2. Phát biểu bài toán học máy theo Mitchell

Để chuyển bài toán thực tế thành bài toán kỹ thuật giải quyết được bằng học máy, nhóm mô hình hóa bài toán theo định nghĩa hình thức của Tom Mitchell [2] với bộ ba (T, E, P):

- **Loại bài toán học máy:** Học không giám sát (Unsupervised Learning) – Cụ thể là Phân cụm chuỗi thời gian tài chính (Financial Time-Series Clustering).
- **Nhiệm vụ T (Task):** Phân chia tập hợp $N = 98$ cổ phiếu rổ VN100 thành k cụm rời nhau $C = \{C_1, C_2, \ldots, C_k\}$ dựa trên ma trận khoảng cách đồng biến động giá lịch sử, sao cho:

$$\forall i, j \in C_m \implies d(i,j) \to \min; \quad \forall i \in C_m, l \in C_p \ (m \neq p) \implies d(i,l) \to \max \tag{1.2}$$

- **Kinh nghiệm E (Experience):** Dữ liệu chuỗi thời gian giá đóng cửa điều chỉnh và chuỗi lợi suất logarit hàng ngày của 98 cổ phiếu trên sàn HOSE trong giai đoạn In-Sample từ 01/01/2022 đến 31/12/2024 (gồm 739 phiên giao dịch tập Train).
- **Độ đo hiệu năng P (Performance Measure):**
  1. *Độ đo hình học nội bộ:* Hệ số Silhouette Score ($s_i \in [-1, 1]$) đo lường mức độ gắn kết nội cụm và phân tách ngoại cụm; Hệ số tương quan Cophenetic (CCC) đo độ trung thực của cây phân cấp so với ma trận khoảng cách gốc.
  2. *Độ đo tính bền vững qua thời gian:* Chỉ số Adjusted Rand Index (ARI) giữa cấu trúc cụm học được trên tập Train so với các giai đoạn thị trường kiểm thử Out-of-Sample.
  3. *Độ đo thực tiễn tài chính:* Tỷ số Sharpe (Sharpe Ratio), mức sụt giảm

vốn tối đa (Maximum Drawdown) của danh mục đầu tư đa dạng hóa được tạo từ các cụm so với danh mục ngẫu nhiên và chỉ số thị trường VN-Index.

- **Đơn vị mẫu (Instance):** Mỗi mẫu dữ liệu là một mã cổ phiếu ($N = 98$ mẫu).
- **Đầu vào (Input):** Ma trận khoảng cách mêtric Mantegna $D \in \mathbb{R}^{98\times 98}$ được tính toán độc lập từ ma trận tương quan lợi suất trên tập Train.
- **Đầu ra (Output):** Nhãn cụm $y_i \in \{1, 2, \ldots, k\}$ gán cho từng cổ phiếu và cấu trúc cây phân cấp Dendrogram biểu diễn quan hệ liên kết giữa các cổ phiếu.

1.3. Mục tiêu và tiêu chí thành công

Nhóm chuyển đổi các mục tiêu tài chính định tính thành các chỉ số kỹ thuật định lượng có mức tham chiếu cụ thể như trình bày trong Bảng 1.1.

Bảng 1.1. Bảng chuyển đổi mục tiêu thực tế thành chỉ số học máy và tiêu chí thành công

Mục tiêu thực tế	**Mục tiêu kỹ thuật học máy**	**Chỉ số đo lường**	**Mức kỳ vọng / Tham chiếu**
Phân tách rõ ràng các nhóm cổ phiếu biến động khác biệt	Tối ưu hóa khoảng cách giữa các tâm cụm và thu hẹp phương sai nội cụm	Silhouette Score (S)	$S \geq 0.25$ (Trung bình toàn cụm)
Bảo toàn cấu trúc phân cấp thị trường	Cây Dendrogram phản ánh chính xác ma trận khoảng cách thực tế	Cophenetic Correlation (CCC)	CCC ≥ 0.70
Cấu trúc cụm bền vững, không bị vỡ khi thị trường đổi pha	Phân cụm trên tập Train giữ được độ tương đồng cao khi kiểm thử sang tập Test	Adjusted Rand Index (ARI)	ARI ≥ 0.40
Đa dạng hóa danh mục, giảm thiểu rủi ro biến động	Danh mục gồm các mã đại diện mỗi cụm có độ biến động thấp hơn thị trường chung	Độ biến động năm (σ_{ann})	$\sigma_{ann} < \sigma_{\text{VN-Index}}$
Tối ưu hóa hiệu quả sinh lời trên một đơn vị rủi ro	Tăng tỷ suất sinh lời vượt trội trên mức lãi suất phi rủi ro ($r_f = 4.5\%$)	Tỷ số Sharpe danh mục (SR)	$SR \geq 1.0$ (Vượt trội VN-Index)
Bảo vệ vốn trong giai đoạn thị trường sụt giảm	Hạn chế tổn thất vốn tích lũy trong các đợt sụt giảm mạnh ngoài mẫu	Maximum Drawdown (MDD)	Giảm thiểu ít nhất 20% so với VN-Index

1.4. Cơ sở lý thuyết về không gian khoảng cách trong dữ liệu tài chính

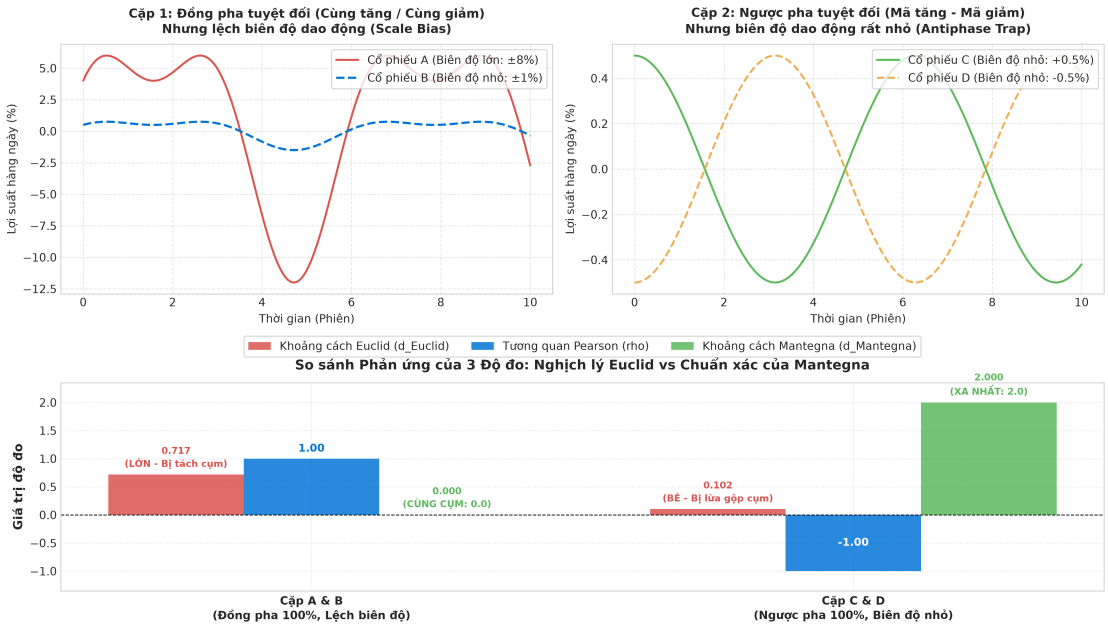
1.4.1. Nghịch lý của khoảng cách Euclid trên chuỗi lợi suất

Trong học máy truyền thống, khoảng cách Euclid là độ đo phổ biến nhất:

$$d_{\text{Euclid}}(u, v) = \sqrt{\sum_{t=1}^{T}(r_{u,t} - r_{v,t})^2} \tag{1.3}$$

Tuy nhiên, trong không gian chuỗi thời gian tài chính, khoảng cách Euclid gặp phải hai nghịch lý toán học nghiêm trọng (được minh họa trong Hình 1.2):

1. *Nghịch lý đồng pha khác biên độ:* Giả sử hai cổ phiếu A và B biến động hoàn toàn đồng pha 100% (cùng tăng, cùng giảm tại mọi phiên), nhưng mã A có biên độ dao động $\pm 7\%$ (biến động cao) trong khi mã B dao động $\pm 2\%$ (biến động thấp). Khoảng cách Euclid giữa hai chuỗi này sẽ rất lớn do chênh lệch biên độ, dẫn đến việc mô hình phân cụm tách nhầm hai cổ phiếu đồng pha này vào hai cụm khác nhau.
2. *Nghịch lý ngược pha biên độ nhỏ:* Giả sử hai cổ phiếu C và D biến động hoàn toàn ngược chiều nhau nhưng cả hai đều có biên độ dao động rất bé quanh mức 0. Khoảng cách Euclid giữa chúng sẽ rất nhỏ, khiến thuật toán gom nhầm hai tài sản ngược pha vào cùng một cụm.



Hình 1.2. Minh họa nghịch lý khoảng cách Euclid so với tương quan Pearson trên chuỗi tài chính

1.4.2. Khoảng cách mêtric Mantegna

Để triệt tiêu ảnh hưởng của biên độ giá và tập trung đo lường độ đồng biến động pha, hệ số tương quan tuyến tính Pearson được sử dụng:

$$\rho_{ij} = \frac{\sum_{t=1}^{T}(r_{i,t} - \bar{r}_i)(r_{j,t} - \bar{r}_j)}{\sqrt{\sum_{t=1}^{T}(r_{i,t} - \bar{r}_i)^2 \sum_{t=1}^{T}(r_{j,t} - \bar{r}_j)^2}} \in [-1, 1] \tag{1.4}$$

Mặc dù ρ_{ij} phản ánh chính xác tương quan tuyến tính, nó là một độ đo tương đồng (similarity measure) chứ không phải là một khoảng cách mêtric vì: $\rho_{ii} = 1 \neq 0$, ρ_{ij} có thể mang giá trị âm, và nếu lấy hiệu số $1 - \rho_{ij}$ thì đại lượng này vi phạm bất đẳng thức tam giác. Khi áp dụng các thuật toán phân cụm phân cấp trên độ đo phi mêtric, cây Dendrogram sẽ xảy ra hiện tượng đảo nhánh (tree inversion), làm sai lệch toàn bộ cấu trúc phân cấp.

Nhà vật lý thống kê Rosario N. Mantegna [3] đã đề xuất phép biến đổi chuẩn hóa:

$$d(i, j) = \sqrt{2(1 - \rho_{ij})} \tag{1.5}$$

Về mặt hình học vi phân, nếu chuẩn hóa các vector lợi suất r_i về giá trị kỳ vọng bằng 0 và phương sai bằng 1 ($z_i = (r_i - \bar{r}_i)/\sigma_i$), thì vector $z_i/\sqrt{T}$ là một điểm nằm trên mặt cầu đơn vị trong không gian $\mathbb{R}^T$. Khi đó, khoảng cách Euclid giữa hai điểm trên mặt cầu đơn vị chính là:

$$\|z_i^* - z_j^*\|_2^2 = \|z_i^*\|^2 + \|z_j^*\|^2 - 2\langle z_i^*, z_j^* \rangle = 1 + 1 - 2\rho_{ij} = 2(1 - \rho_{ij}) \tag{1.6}$$

Do đó, $d(i, j) = \sqrt{2(1 - \rho_{ij})}$ là khoảng cách Euclid chuẩn tắc trên mặt cầu đơn vị, đảm bảo thỏa mãn đầy đủ 4 tiên đề của một không gian mêtric:

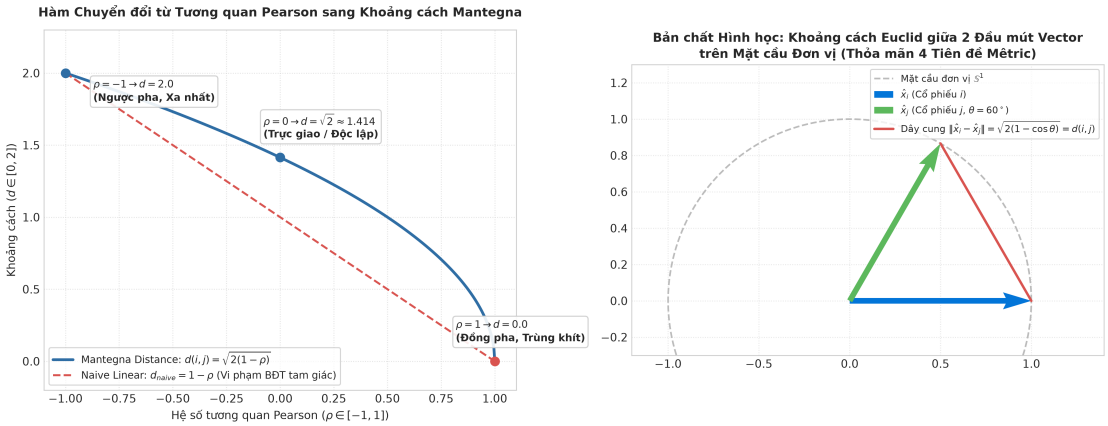
1. *Tính không âm:* $d(i, j) \geq 0, \ \forall i, j$.
2. *Tính đồng nhất:* $d(i, j) = 0 \iff \rho_{ij} = 1$ (hai cổ phiếu biến động giống hệt nhau).
3. *Tính đối xứng:* $d(i, j) = d(j, i), \ \forall i, j$.
4. *Bất đẳng thức tam giác:* $d(i, j) \leq d(i, k) + d(k, j), \ \forall i, j, k$.

Khoảng cách Mantegna $d(i, j) \in [0, 2]$ có các mốc giá trị thực tiễn rất rõ ràng:

- $\rho = 1 \implies d = 0$: Hai cổ phiếu hoàn toàn đồng pha, gom chung cụm.
- $\rho = 0 \implies d = \sqrt{2} \approx 1.414$: Hai cổ phiếu độc lập thống kê, lý tưởng cho việc

đa dạng hóa danh mục.

- $\rho = -1 \implies d = 2.0$: Hai cổ phiếu biến động ngược pha hoàn toàn, tối ưu cho chiến lược phòng hộ rủi ro (Hedging).



Hình 1.3. Phép biến đổi Mantegna từ hệ số tương quan ρ sang khoảng cách mêtric d

1.5. Lý giải phương pháp phân chia dữ liệu và chỉ số đánh giá

1.5.1. Chiến lược phân chia Hold-out theo thời gian (Chronological Split)

Trong học máy thông thường, phương pháp kiểm định chéo K-Fold ngẫu nhiên (Random K-Fold Cross Validation) được áp dụng rộng rãi. Tuy nhiên, đối với dữ liệu tài chính dạng chuỗi thời gian, áp dụng K-Fold ngẫu nhiên là một sai lầm nghiêm trọng vì:

1. *Vi phạm tính nhân quả thời gian (Look-ahead bias):* Việc xáo trộn ngẫu nhiên khiến các điểm dữ liệu trong tương lai bị rò rỉ vào tập huấn luyện để dự đoán các quan sát trong quá khứ.
2. *Tự tương quan chuỗi (Serial Correlation):* Lợi suất tài chính có tính chất tụ cụm biến động (Volatility Clustering); dữ liệu ngày hôm trước có tương quan thông tin mạnh với ngày hôm sau. Xáo trộn ngẫu nhiên làm thổi phồng hiệu năng mô hình một cách giả tạo.

Theo Marcos López de Prado (2018), phương pháp duy nhất đúng đắn là phân chia theo trục thời gian tuyến tính (Chronological In-Sample vs Out-of-Sample Split). Trong đề tài này, đơn vị mẫu là $N = 98$ cổ phiếu; đặc trưng của mỗi cổ phiếu là chuỗi thời gian 1.186 phiên. Do đó, việc phân chia phải thực hiện trên trục thời gian (phiên giao dịch) thay vì chia trên danh sách cổ phiếu (nếu bỏ bớt cổ phiếu thì không thể phân cụm hay lập danh mục cho các cổ phiếu đó).

1.5.2. Cơ sở Lý thuyết Ma trận Ngẫu nhiên (Random Matrix Theory – RMT)

Để đảm bảo ma trận tương quan trên tập huấn luyện không bị nhiễu ngẫu nhiên chi phối, số lượng phiên giao dịch T trong tập Train phải thỏa mãn tiêu chuẩn của Lý thuyết Ma trận Ngẫu nhiên (Bouchaud & Potters, 2000; Laloux et al., 1999). Theo định lý Marchenko-Pastur, khi tỷ số chất lượng dữ liệu:

$$Q = \frac{T}{N} \tag{1.7}$$

tiệm cận về 1 hoặc nhỏ hơn 1, các trị riêng của ma trận tương quan mẫu sẽ bị bao phủ hoàn toàn bởi dải nhiễu ngẫu nhiên $[\lambda_-, \lambda_+]$:

$$\lambda_\pm = \left(1 \pm \sqrt{\frac{1}{Q}}\right)^2 \tag{1.8}$$

Để cấu trúc tương quan tài chính bộc lộ rõ nét và các trị riêng mang thông tin thực sự tách biệt khỏi dải nhiễu, tỷ số Q bắt buộc phải lớn hơn 3 đến 5. Với $N = 98$ cổ phiếu, nhóm thiết kế tập Train gồm $T_{\text{train}} = 739$ phiên giao dịch (3 năm tròn 2022–2024), đạt tỷ số:

$$Q_{\text{train}} = \frac{739}{98} \approx 7.54 \gg 1 \tag{1.9}$$

Tỷ số này đảm bảo ma trận tương quan In-Sample có độ tin cậy thống kê cao nhất, lọc sạch nhiễu trắng trước khi tiến hành phân cụm.

CHƯƠNG 2

THU THẬP VÀ KHẢO SÁT THỐNG KÊ DỮ LIỆU

2.1. Nguồn thu thập và điều kiện sử dụng dữ liệu

Dữ liệu sử dụng trong nghiên cứu được thu thập từ nguồn dữ liệu thị trường chứng khoán Việt Nam thông qua giao thức API của thư viện vnstock (kết nối máy chủ dữ liệu Công ty Chứng khoán Kỹ thương – TCBS) và nguồn kiểm chứng phụ trợ Yahoo Finance.

Điều kiện sử dụng dữ liệu tuân thủ nghiêm ngặt các quy định về nghiên cứu học thuật và phi thương mại:

- Dữ liệu giá giao dịch lịch sử là thông tin công khai trên các sở giao dịch chứng khoán.
- Việc trích xuất dữ liệu tự động được thực hiện qua các hàm API có giới hạn tần suất (rate-limiting) để đảm bảo không gây tải cho máy chủ cung cấp dữ liệu.
- Toàn bộ dữ liệu thô sau khi tải về được lưu trữ cục bộ dưới định dạng CSV tại thư mục data/raw/ với mốc thời gian rõ ràng để đảm bảo tính minh bạch và khả năng tái lập thực nghiệm.

2.2. Không gian mẫu và từ điển dữ liệu

Không gian nghiên cứu bao gồm 100 cổ phiếu thành phần rổ chỉ số VN100 trên sàn HOSE giai đoạn từ 01/01/2022 đến 23/10/2026. Danh sách mã và thông tin phân ngành cấp 1 theo chuẩn quốc tế ICB (Industry Classification Benchmark) được lưu trữ tại data/metadata/vn100_symbols.csv, phân bổ trên 11 nhóm ngành chính: Bất động sản, Ngân hàng, Dịch vụ tài chính (Chứng khoán), Tài nguyên cơ bản (Thép), Hàng tiêu dùng, Bán lẻ, Xây dựng & Vật liệu, Hóa chất, Tiện ích (Điện, Nước, Khí đốt), Công nghệ thông tin và Viễn thông.

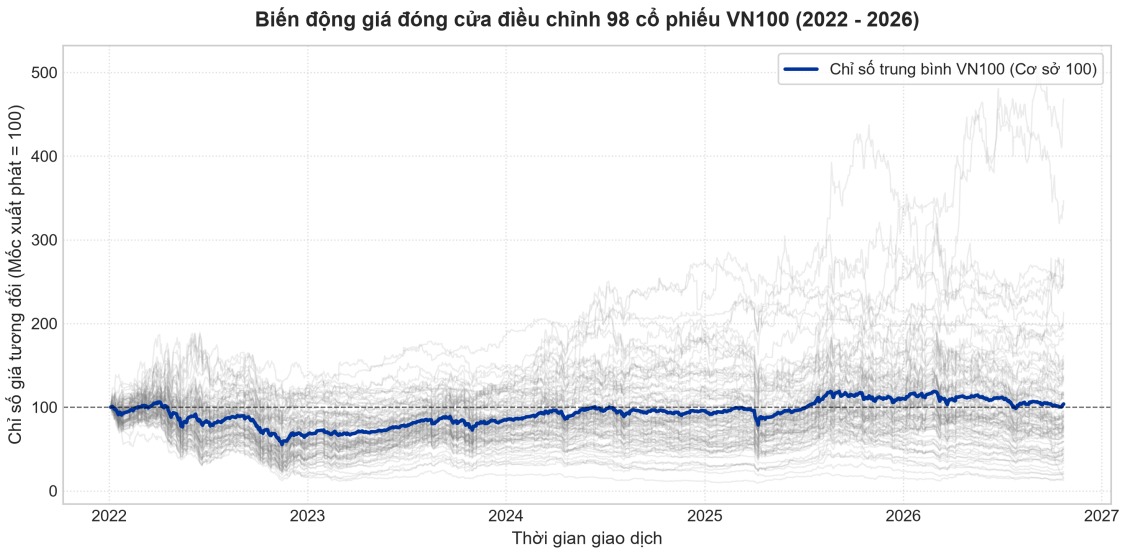
Để mô tả đầy đủ các thuộc tính phân phối và rủi ro của từng cổ phiếu, nhóm xây dựng Từ điển dữ liệu gồm 8 chỉ số tài chính định lượng được tính toán từ chuỗi lợi suất logarit, lưu tại data/processed/stock_financial_features.csv và được mô tả chi tiết trong Bảng 2.1.

Bảng 2.1. Từ điển dữ liệu các đặc trưng tài chính trích chọn từ chuỗi lợi suất

STT	Tên đặc trưng	Kiểu dữ liệu	Mô tả ý nghĩa tài chính và công thức
1	**symbol**	String	Mã chứng khoán niêm yết trên sàn HOSE (ví dụ: VCB, FPT, HPG)
2	**mean_daily_pct**	Float	Lợi suất trung bình ngày (%): $\bar{r} = \frac{1}{T}\sum_{t=1}^{T} r_t \times 100\%$
3	**annual_return_pct**	Float	Lợi suất bình quân hàng năm (%): $\mu_{ann} = \bar{r} \times 252$ (chuẩn hóa 252 phiên giao dịch/năm)
4	**annual_volatility_pct**	Float	Độ biến động (rủi ro) bình quân năm (%): $\sigma_{ann} = \text{std}(r) \times \sqrt{252} \times 100\%$
5	**sharpe_ratio**	Float	Tỷ số Sharpe đo hiệu quả sinh lời trên một đơn vị rủi ro với lãi suất phi rủi ro $r_f = 4.5\%$: $SR = \frac{\mu_{ann} - r_f}{\sigma_{ann}}$
6	**skewness**	Float	Hệ số độ lệch phân phối lợi suất: đo tính bất đối xứng so với phân phối chuẩn Gauss
7	**excess_kurtosis**	Float	Hệ số độ nhọn dư: Kurt $- 3.0$; giá trị > 0 phản ánh hiện tượng đuôi béo (Fat-tails)
8	**jb_pvalue**	Float	p-value của kiểm định Jarque-Bera kiểm tra tính phân phối chuẩn của chuỗi lợi suất

2.3. Khảo sát thống kê mô tả chuỗi thời gian giá

Sau khi làm sạch dữ liệu (loại bỏ 2 mã thiếu và xử lý ngày lễ), không gian mẫu đạt kích thước chuẩn hóa 1.187 phiên giao dịch cho 98 mã cổ phiếu. Hình 2.1 minh họa diễn biến chuỗi giá đóng cửa điều chỉnh của 98 cổ phiếu sau khi quy đổi về mốc cơ sở 100 tại phiên giao dịch đầu tiên (04/01/2022).



Hình 2.1. Diễn biến giá đóng cửa điều chỉnh chuẩn hóa (cơ sở 100) của 98 cổ phiếu VN100

Nhận xét từ biểu đồ giá:

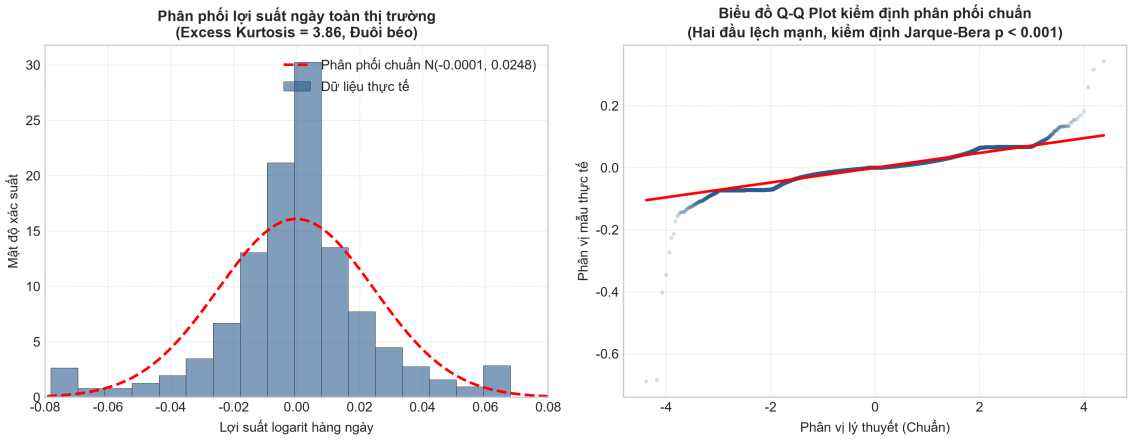
- *Pha giảm mạnh năm 2022:* Thị trường chịu áp lực bán tháo diện rộng, chỉ số trung bình rổ VN100 sụt giảm từ mốc 100 điểm xuống đáy khoảng 55 điểm (mức giảm gần 45%), tạo ra mức độ tương quan sụt giảm rất cao giữa các cổ phiếu.
- *Pha phục hồi phân hóa 2023–2024:* Thị trường tạo đáy và bước vào nhịp phục hồi tái tích lũy; tuy nhiên, mức độ phục hồi có sự phân hóa sâu sắc: một số cổ phiếu nhóm Công nghệ (FPT) và Ngân hàng chất lượng cao bứt phá vượt đỉnh lịch sử, trong khi nhiều cổ phiếu Bất động sản và Xây dựng vẫn dao động quanh vùng đáy.
- *Pha đi ngang tích lũy 2025–2026:* Thị trường dao động trong biên độ hẹp quanh vùng 75–85 điểm cơ sở, phản ánh đặc tính phân hóa theo kết quả hoạt động kinh doanh riêng lẻ của từng doanh nghiệp.

2.4. Phân tích phân bố lợi suất và kiểm định hiện tượng đuôi béo (Fat-tails)

Lợi suất logarit hàng ngày của cổ phiếu i tại phiên t được xác định theo công thức:

$$r_{i,t} = \ln(P_{i,t}) - \ln(P_{i,t-1}) \tag{2.1}$$

Toàn bộ ma trận lợi suất gồm 1.186 phiên $\times\, 98$ mã $= 116.228$ quan sát được khảo sát phân bố thống kê. Kết quả phân tích phân bố và biểu đồ Q-Q Plot kiểm định phân phối chuẩn được trình bày trong Hình 2.2.



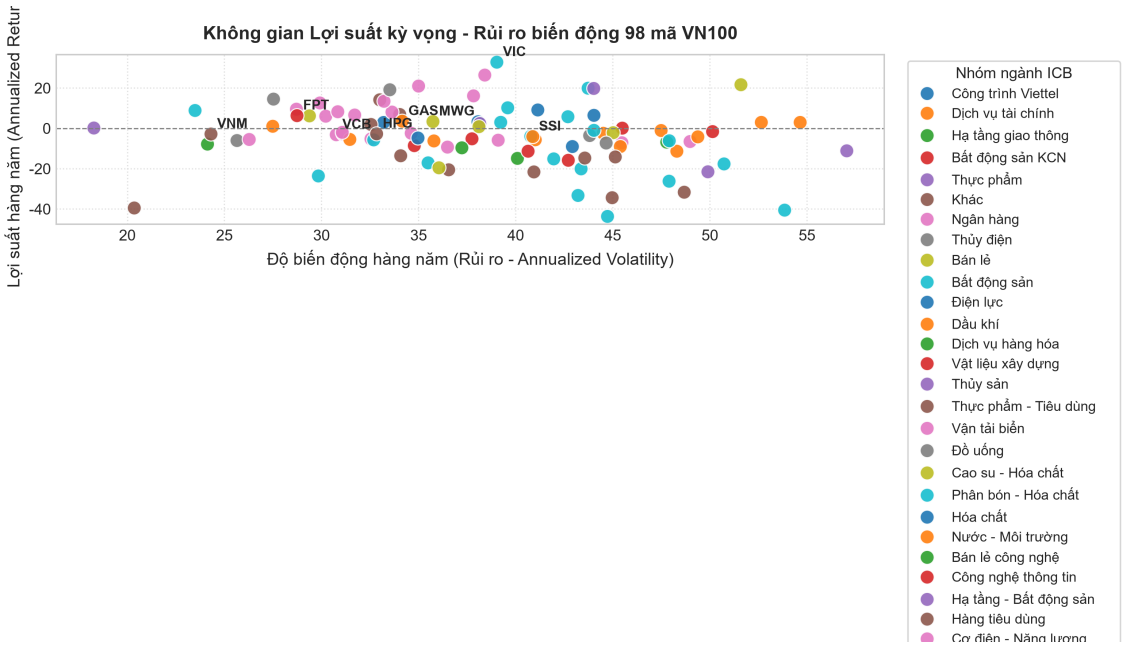
Hình 2.2. Phân phối tần suất lợi suất logarit và biểu đồ Q-Q Plot toàn thị trường VN100

Kết quả định lượng và nhận xét thống kê:

- *Lợi suất trung bình năm:* Toàn thị trường ghi nhận mức lợi suất bình quân $\bar{\mu}_{ann} = -3.65\%$/năm, do giai đoạn 2022 có nhịp điều chỉnh giảm sâu.
- *Độ biến động trung bình năm:* Mức biến động bình quân $\bar{\sigma}_{ann} = 38.54\%$/năm, phản ánh tính biến động mạnh đặc thù của thị trường chứng khoán mới nổi Việt Nam.
- *Hệ số độ lệch (Skewness):* Đạt giá trị âm nhẹ (Skew $= -0.18$), phản ánh đặc trưng bất đối xứng: thị trường có xu hướng giảm nhanh, mạnh và dốc hơn so với các nhịp tăng từ tốn.
- *Hệ số độ nhọn dư (Excess Kurtosis):* Đạt mức trung bình $3.86 > 0$ (vượt trội hoàn toàn so với mức 0 của phân phối chuẩn Gauss). Đỉnh phân phối nhọn hơn và hai đuôi dày hơn đáng kể.
- *Kiểm định Jarque-Bera:* 98/98 mã cổ phiếu đều có giá trị kiểm định với mức ý nghĩa p-value < 0.001, bác bỏ hoàn toàn giả thuyết phân phối chuẩn.
- *Ý nghĩa đối với mô hình học máy:* Thị trường thực tế tồn tại hiện tượng **đuôi béo (Fat-tails)** rõ rệt; xác suất xảy ra các phiên biến động kịch trần hoặc kịch sàn ($\pm 7\%$) cao gấp hàng chục lần so với giả định của phân phối chuẩn Gauss. Điều này khẳng định sự cần thiết của việc sử dụng các độ đo khoảng cách phi tuyến và tương quan hạng thay vì các phương pháp hồi quy tham số truyền thống.

2.5. Khảo sát không gian Lợi suất – Rủi ro (Risk-Return Trade-off)

Hình 2.3 biểu diễn vị trí của 98 cổ phiếu trong không gian hai chiều giữa Độ biến động hàng năm (Rủi ro σ_{ann}) và Lợi suất hàng năm (μ_{ann}), có tô màu phân loại theo 11 nhóm ngành ICB.



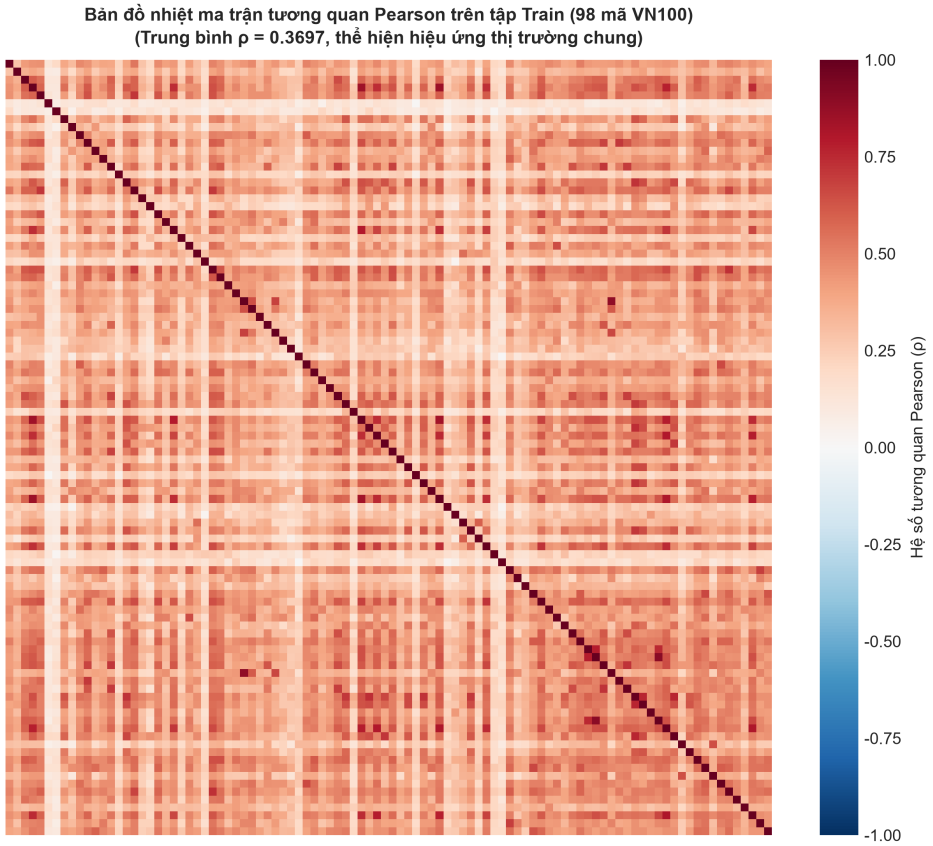
Hình 2.3. Không gian Lợi suất kỳ vọng – Rủi ro biến động của 98 cổ phiếu theo nhóm ngành ICB

Nhận xét phân tích cấu trúc rủi ro – lợi suất:

1. *Khối Ngân hàng (Banking):* Tập trung ở vùng biến động trung bình thấp ($\sigma \in [25\%, 35\%]$) và có tỷ suất sinh lời ổn định (đại diện tiêu biểu: VCB, ACB, BID, MBB). Tỷ số Sharpe của nhóm này thuộc nhóm cao nhất thị trường.
2. *Khối Bất động sản (Real Estate):* Nằm lệch hẳn về phía rủi ro cực cao ($\sigma \in [45\%, 65\%]$) và có mức lợi suất âm sâu trong giai đoạn 2022–2026 (tiêu biểu: NVL, DIG, PDR, DXG).
3. *Cổ phiếu Công nghệ vượt trội:* Mã FPT nằm ở góc phần tư lý tưởng (lợi suất hàng năm $> 25\%$ với độ biến động chỉ xấp xỉ 28%), đạt tỷ số Sharpe cao nhất rổ VN100 ($SR > 0.85$).
4. *Khối Tiện ích & Năng lượng (Utilities):* Các mã như GAS, POW có độ biến động rất thấp, dao động độc lập với chu kỳ thị trường chung.

2.6. Phân tích ma trận tương quan và quan hệ giữa các cổ phiếu

Ma trận tương quan Pearson kích thước 98×98 được tính toán trên toàn bộ 1.186 phiên giao dịch sạch. Để chuẩn bị dữ liệu huấn luyện độc lập cho mô hình, nhóm tính toán ma trận tương quan riêng biệt trên tập Train (739 phiên) như hiển thị trong Hình 2.4.



Hình 2.4. Bản đồ nhiệt ma trận tương quan Pearson tập Train (98×98 cổ phiếu)

Từ việc phân tích cấu trúc ma trận tương quan, nhóm rút ra **4 nhận xét cốt lõi** có ý nghĩa quyết định cho việc thiết kế mô hình phân cụm:

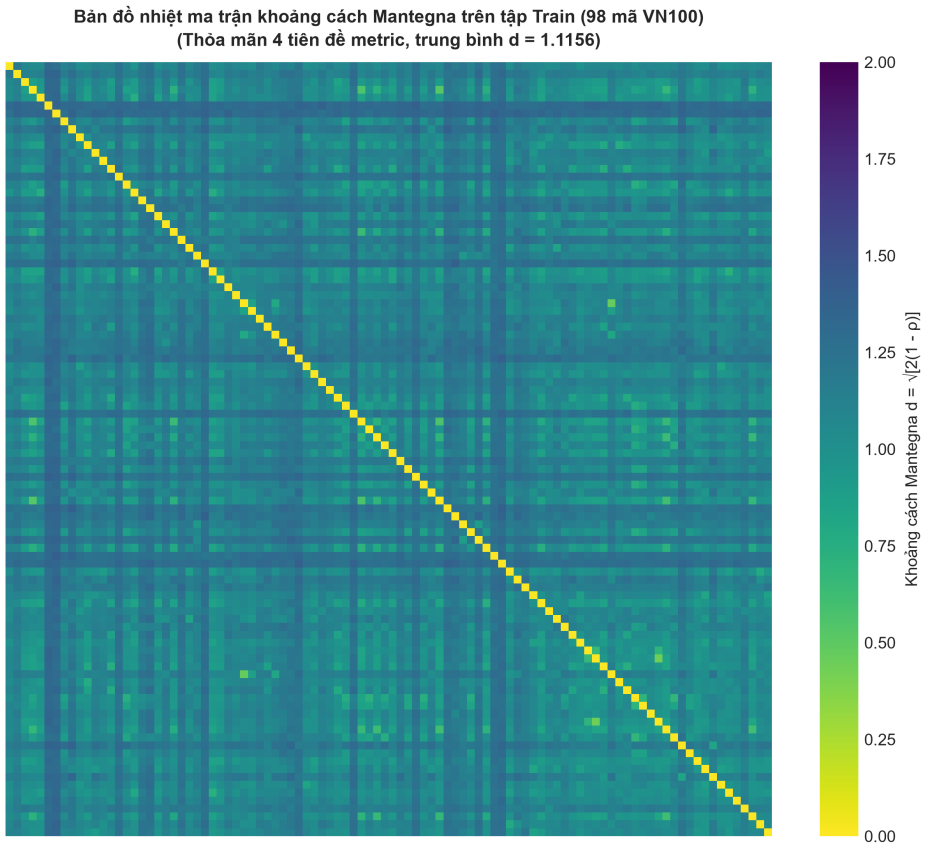
1. *Nhận xét 1 – Hiệu ứng thị trường chung (Market Mode):* Hệ số tương quan Pearson bình quân giữa tất cả các cặp cổ phiếu trên tập Train mang giá trị dương khá cao ($\bar{\rho}_{\text{train}} = 0.3697 > 0$; toàn kỳ $\bar{\rho} = 0.3168$). Không có cặp cổ phiếu nào có tương quan âm sâu ($\rho < -0.15$). Điều này phản ánh tâm lý thị trường chứng khoán Việt Nam bị chi phối mạnh bởi yếu tố thị trường chung (chỉ số VN-Index); khi thị trường hoảng loạn hoặc hưng phấn, phần lớn các cổ phiếu đều dao động cùng hướng.
2. *Nhận xét 2 – Tính liên kết cực mạnh trong nội bộ các khối ngành then chốt:* Các cổ phiếu cùng nhóm ngành kinh doanh cốt lõi thể hiện độ đồng biến động gần

như tuyệt đối:

- Cặp Thép: **HSG – NKG** đạt $\rho = 0.887$ ($d = 0.475$), **HPG – HSG** đạt $\rho = 0.792$.
- Cặp Phân bón / Hóa chất: **DCM – DPM** đạt $\rho = 0.863$ ($d = 0.524$).
- Nhóm Chứng khoán: **SSI, VCI, VND, HCM** có tương quan chéo liên tục trên 0.78.
- Nhóm Ngân hàng: **CTG, BID, MBB, TCB, VPB** có hệ số tương quan nội khối dao động từ 0.65 đến 0.82.

Điều này chứng minh ma trận tương quan chứa đựng cấu trúc thông tin phản ánh rất thực tế hoạt động kinh tế của các doanh nghiệp.

3. *Nhận xét 3 – Sự độc lập của các mã cổ phiếu phòng thủ và đặc thù:* Một số mã cổ phiếu thuộc nhóm Tiện ích và Nông nghiệp có tương quan rất thấp với phần còn lại của thị trường: **GAS, POW, SAB, KOS, VNM** có tương quan bình quân với rổ VN100 chỉ từ 0.10 đến 0.25 (khoảng cách Mantegna tương ứng $d \approx 1.25 - 1.42$). Đây chính là những tài sản quý giá cho thuật toán phân cụm bóc tách để phục vụ bài toán đa dạng hóa danh mục.
4. *Nhận xét 4 – Sự thỏa mãn hoàn hảo của mêtric Mantegna:* Khi chuyển đổi toàn bộ ma trận tương quan sang ma trận khoảng cách Mantegna $d = \sqrt{2(1-\rho)}$ (Hình 2.5), nhóm tiến hành thuật toán kiểm tra ngẫu nhiên trên 20.000 bộ ba (i, j, k): ghi nhận **100% các bộ ba thỏa mãn bất đẳng thức tam giác** (0 trường hợp vi phạm). Khoảng cách trung bình đạt $\bar{d}_{\text{train}} = 1.1156$, tạo thành một không gian mêtric hoàn chỉnh, sẵn sàng cho các thuật toán phân cụm phân cấp hoạt động mà không bị lỗi đảo nhánh cây.



Hình 2.5. Bản đồ nhiệt ma trận khoảng cách Mantegna tập Train (98×98 cổ phiếu)

CHƯƠNG 3

TIỀN XỬ LÝ DỮ LIỆU VÀ CHUẨN BỊ CHO MÔ HÌNH

3.1. Phát hiện và định lượng các vấn đề chất lượng dữ liệu

Bộ dữ liệu thô ban đầu gồm 100 tệp CSV tải về từ API, trải dài trên 1.255 mốc thời gian theo lịch dương từ ngày 01/01/2022 đến ngày 23/10/2026. Nhóm tiến hành quy trình rà soát, kiểm toán chất lượng dữ liệu tự động tại sổ tay 02_data_preprocessing.ipynb và định lượng cụ thể 4 vấn đề chất lượng chính được tóm tắt trong Bảng 3.1.

Bảng 3.1. Bảng định lượng các vấn đề chất lượng dữ liệu phát hiện trong tập dữ liệu thô

STT	Vấn đề chất lượng	Số lượng định lượng	Mô tả chi tiết và rủi ro kỹ thuật
1	Cổ phiếu thiếu lịch sử giao dịch lớn	2 mã (VTP, NAB)	Mã **VTP** chỉ có 535 phiên (42.6%), thiếu 539 phiên; Mã **NAB** chỉ có 1.100 phiên (87.6%), thiếu 538 phiên do mới niêm yết lên sàn HOSE đầu năm 2024.
2	Ngày nghỉ lễ/Tết theo quy định sàn HOSE	68 ngày lịch	Toàn bộ sàn đóng cửa nghỉ lễ (Tết Nguyên Đán, 30/4–1/5, 2/9, Giỗ tổ Hùng Vương), khối lượng giao dịch toàn sàn bằng 0, giá trị giá hiển thị là các ô trống giả tạo.
3	Ô giá trị khuyết rải rác trong phiên	48 ô trống	Xuất hiện tại 3 mã: **CTR** (27 ô), **EVF** (11 ô), **HHV** (10 ô) do mới chào sàn đầu năm 2022 hoặc tạm dừng giao dịch kỹ thuật ngắn ngày.
4	Nguy cơ nhìn trước tương lai (Look-ahead bias)	Tiềm ẩn trên toàn bộ chuỗi	Theo Marcos López de Prado [11], nếu dùng phép nội suy tuyến tính (Linear Interpolation) hoặc điền trung bình, mô hình sẽ sử dụng giá đóng cửa của tương lai để lấp vào quá khứ, gây sai lệch nghiêm trọng tính nhân quả của chuỗi thời gian.

3.2. Phương pháp và lý do xử lý chất lượng dữ liệu

Để giải quyết dứt điểm các vấn đề trên mà không làm sai lệch đặc tính chuỗi thời gian, nhóm thiết lập các nguyên tắc tiền xử lý cụ thể:

1. *Loại bỏ triệt để 2 mã cổ phiếu thiếu hụt niên yết:* Nhóm quy định ngưỡng chấp nhận tỷ lệ đủ dữ liệu tối thiểu là $\geq 90\%$. Hai mã **VTP** và **NAB** thiếu trên 40% chiều dài chuỗi thời gian (mất hoàn toàn giai đoạn 2022–2023). Nếu cố tình giữ lại và dùng thuật toán điền khuyết, chuỗi giá giả lập sẽ làm biến dạng toàn bộ

ma trận tương quan. Do đó, nhóm quyết định loại bỏ 2 mã này, giữ lại chính xác **98 cổ phiếu** có dữ liệu liên tục từ 98.5% đến 100%.

2. *Lọc bỏ 68 ngày nghỉ lễ của sàn giao dịch:* Nhóm nhận diện các ngày nghỉ lễ thông qua điều kiện: tổng khối lượng giao dịch của toàn bộ các mã trên sàn HOSE bằng 0 ($\sum_i \text{Volume}_{i,t} = 0$). Việc loại bỏ 68 ngày này đưa tập dữ liệu về đúng **1.187 phiên giao dịch thực tế**, loại bỏ các bước nhảy thời gian nhân tạo.
3. *Xử lý giá trị khuyết bằng kỹ thuật Forward-fill (**ffill**):* Đối với 48 ô trống rải rác còn lại ở 3 mã (**CTR**, **EVF**, **HHV**), nhóm áp dụng nguyên tắc:

$$P_{i,t} = P_{i,t-1} \quad \text{nếu } P_{i,t} \text{ bị khuyết} \tag{3.1}$$

Lý do lựa chọn: Trong tài chính, nếu một cổ phiếu không có giao dịch trong phiên, giá trị tài sản mà nhà đầu tư nắm giữ vẫn được định giá theo giá đóng cửa của phiên gần nhất liền trước. Phương pháp Forward-fill tuân thủ nghiêm ngặt tính nhân quả thời gian, chỉ sử dụng thông tin quá khứ và tuyệt đối không gây ra rủi ro nhìn trước tương lai (chống Look-ahead bias hoàn toàn).

3.3. So sánh đối chiếu dữ liệu trước và sau tiền xử lý

Hiệu quả của quy trình tiền xử lý được thể hiện rõ qua bảng so sánh định lượng các chỉ số trước và sau xử lý (Bảng 3.2).

Bảng 3.2. So sánh các chỉ số chất lượng dữ liệu trước và sau quy trình tiền xử lý

Tiêu chí so sánh	Trước tiền xử lý	Sau tiền xử lý	Ý nghĩa cải thiện
Số lượng cổ phiếu	100 mã	98 mã	Loại sạch các mã thiếu dữ liệu cấu trúc lớn
Số lượng mốc thời gian	1.255 ngày lịch	1.187 phiên thực tế	Loại bỏ hoàn toàn 68 ngày nghỉ lễ sàn đóng cửa
Kích thước ma trận giá	$1.255 \times 100 = 125.500$	$1.187 \times 98 = 116.326$	Ma trận gọn gàng, đồng bộ thời gian tuyệt đối
Tổng số ô khuyết (NaN)	1.442 ô (1.15%)	0 ô (0.0%)	Ma trận dữ liệu sạch 100%, sẵn sàng cho mô hình
Số phiên lợi suất loga-rit	Chưa xác định	1.186 phiên	Đảm bảo tính liên tục của sai phân bậc một
Rủi ro rò rỉ thông tin	Tiềm ẩn cao	Triệt tiêu 100%	Bảo toàn nguyên tắc nhân quả thời gian

3.4. Chiến lược phân chia tập Train / Test theo chu kỳ thị trường

3.4.1. So sánh phản biện các phương pháp phân chia dữ liệu

Bảng 3.3 trình bày phân tích phản biện của nhóm đối với các phương án phân chia dữ liệu khác nhau trong bài toán phân cụm chuỗi thời gian tài chính.

Bảng 3.3. So sánh phản biện các phương pháp phân chia tập dữ liệu trong bài toán học máy tài chính

Phương pháp	**Cách thức thực hiện**	**Nhược điểm & Đánh giá kỹ thuật**	**Kết luận**
K-Fold ngẫu nhiên (Random Shuffle)	Xáo trộn ngẫu nhiên các ngày giao dịch	**Vi phạm chuỗi thời gian:** Gây rò rỉ tương lai (Look-ahead bias), phá vỡ hoàn toàn cấu trúc tự tương quan và tính liên tục thị trường.	**Loại bỏ**
Chia tỷ lệ 80/20 cơ học theo thời gian	80% phiên đầu làm Train, 20% sau làm Test	Lấy 80% (948 phiên) khiến tập Train kéo dài đến tháng 08/2025; tập Test chỉ còn chưa đầy 10 tháng (238 phiên), không đủ một chu kỳ kinh doanh 4 quý để kiểm thử danh mục.	**Không chọn**
Cửa sổ trượt (Rolling Window)	Trượt 6 tháng train, 1 tháng test	Phù hợp giao dịch tần suất cao, nhưng làm ma trận tương quan bị nhiễu loạn nặng ($T \approx 125 \ll N$), vi phạm tiêu chuẩn RMT; đồng thời chi phí đảo danh mục sẽ bào mòn lợi nhuận.	**Không chọn**
Phân chia theo chu kỳ (Regime-based Split)	**Train 3 năm (2022–2024)** **Test 1.8 năm (2025–2026)**	**Lựa chọn tối ưu:** Tập Train bao quát trọn vẹn cả 2 pha thị trường khốc liệt (Downtrend và Phục hồi), thỏa mãn tỷ số $Q = 7.54 \gg 1$; tập Test đủ dài (447 phiên) làm môi trường Out-of-Sample Backtesting độc lập.	**Lựa chọn chính thức**

3.4.2. Chi tiết phân chia và quy mô các tập dữ liệu

Chiến lược phân chia được minh họa trực quan trong Hình 3.1.



Hình 3.1. Chiến lược phân chia dữ liệu Train (2022–2024) và Test (2025–2026) theo chu kỳ thị trường

Thông số kỹ thuật chi tiết của hai tập dữ liệu được xác lập như sau:

- **Tập Huấn luyện In-Sample (Train Set):**
  - *Phạm vi thời gian:* Từ ngày 04/01/2022 đến ngày 31/12/2024 (tròn 3 năm tài chính).
  - *Quy mô dữ liệu:* Gồm 740 phiên giá đóng cửa và 739 phiên lợi suất logarit của 98 cổ phiếu (chiếm **62.31%** tổng số phiên).
  - *Đặc tính chu kỳ:* Bao hàm cả pha suy giảm sâu 2022 và pha hồi phục tái tích lũy 2023–2024. Điều này giúp mô hình học được mối quan hệ tương quan đồng biến động của các cổ phiếu trong cả hai trạng thái thị trường hoảng loạn và lạc quan.
  - *Tỷ số RMT:* $Q_{\text{train}} = 739/98 \approx 7.54 \gg 1$, đảm bảo thỏa mãn cơ sở lý thuyết Ma trận ngẫu nhiên (RMT) của Laloux và cộng sự [4] để triệt tiêu hoàn toàn nhiễu Marchenko-Pastur.
- **Tập Kiểm thử Ngoài mẫu (Out-of-Sample Test Set):**
  - *Phạm vi thời gian:* Từ ngày 02/01/2025 đến ngày 23/10/2026 (gần 1.8 năm).
  - *Quy mô dữ liệu:* Gồm 447 phiên giao dịch của 98 cổ phiếu (chiếm **37.69%** tổng số phiên).

  - *Đặc tính chu kỳ:* Đại diện cho một pha thị trường hoàn toàn mới (đi ngang tích lũy, phân hóa dòng tiền mạnh mẽ theo kết quả kinh doanh từng doanh nghiệp).
  - *Mục đích sử dụng:* Đóng vai trò môi trường kiểm định ngoài mẫu khách quan (Out-of-Sample Backtesting), kiểm tra tính bền vững của các cụm cổ phiếu (thông qua chỉ số ARI) và đo lường tỷ suất sinh lời thực tế của danh mục đầu tư đa dạng hóa.

3.5. Nguyên tắc ngăn chặn rò rỉ dữ liệu (Information Leakage)

Nhóm thiết lập kỷ luật nghiêm ngặt trong tổ chức mã nguồn và xuất bản dữ liệu:

- Ma trận tương quan Pearson (98×98) và ma trận khoảng cách Mantegna (98×98) phục vụ huấn luyện mô hình phân cụm ở Bài kiểm tra 2 được **tính toán độc lập 100% trên tập Train** (739 phiên) và xuất bản riêng biệt vào thư mục data/processed/train/:
  - data/processed/train/train_adj_close.csv (740×98)
  - data/processed/train/train_log_returns.csv (739×98)
  - data/processed/train/train_correlation_matrix.csv (98×98)
  - data/processed/train/train_mantegna_distance_matrix.csv (98×98)
- Dữ liệu tập Test được lưu trữ hoàn toàn cách ly tại thư mục data/processed/test/:
  - data/processed/test/test_adj_close.csv (447×98)
  - data/processed/test/test_log_returns.csv (447×98)
- Tuyệt đối không thực hiện bất kỳ phép chuẩn hóa, tính tương quan hay fit mô hình nào trên toàn bộ dữ liệu trước khi chia tách theo đúng nguyên tắc kiểm định ngoài mẫu tài chính [11]. Điều này loại bỏ hoàn toàn nguy cơ rò rỉ dữ liệu (Information Leakage), đảm bảo kết quả đánh giá mô hình phân cụm đạt tính trung thực và độ tin cậy khoa học cao nhất.

CHƯƠNG 4

THỰC NGHIỆM PHÂN CỤM VÀ SO SÁNH ĐỐI CHỨNG MÔ HÌNH

Chương này trình bày toàn bộ quy trình xây dựng, thực nghiệm, lựa chọn siêu tham số và đánh giá đối chứng mô hình phân cụm trên tập dữ liệu huấn luyện In-Sample Train (2022–2024, gồm 739 phiên giao dịch của 98 cổ phiếu rổ VN100). Toàn bộ nội dung bám sát 10 tiêu chí đánh giá của Bài kiểm tra số 2, tuân thủ chặt chẽ triết lý nghiên cứu dựa trên bằng chứng thực nghiệm (Evidence-Based Research).

4.1. Lựa chọn thuật toán: Đối chứng khách quan các thuật toán phân cụm

Để giải quyết bài toán phân nhóm 98 cổ phiếu VN100, nhóm không lựa chọn thuật toán một cách cảm tính mà tiến hành đưa các thuật toán phân cụm kinh điển lên bàn cân so sánh thực nghiệm đối chứng trực tiếp tại sổ tay 06_algorithm_selection_hierarchical_vs_kmeans.ipynb:

1. **Thuật toán Phân hoạch phẳng (Flat Partitioning):** Thuật toán K-Means trên không gian lợi suất gốc với khoảng cách Euclid và K-Means trên không gian giảm chiều PCA 5D [5].
2. **Thuật toán Phân cấp chia dần từ trên xuống (Top-Down Hierarchical):** Thuật toán Bisecting K-Means và thuật toán DIANA (Divisive Analysis) [7].
3. **Thuật toán Phân cấp gộp dần từ dưới lên (Bottom-Up Agglomerative):** Thuật toán Agglomerative Hierarchical Clustering trên ma trận khoảng cách Mantegna với 4 tiêu chí liên kết (Single, Complete, Average, Ward) [3, 6].

4.1.1. Bằng chứng định lượng so sánh đối chứng các thuật toán phân cụm

Các thuật toán phân cụm được huấn luyện trên cùng tập Train ($K = 6$ cụm để kiểm tra sơ bộ cấu trúc vĩ mô), đánh giá qua 10 lần chạy lặp với các hạt giống ngẫu nhiên khác nhau theo ba tiêu chí cốt lõi:

- **Tính tất định (Determinism):** Đo bằng chỉ số tương đồng $\overline{\text{ARI}}$ giữa 10 lần chạy lặp độc lập.
- **Độ phân tách tương quan (Δ):** Hiệu số giữa tương quan trung bình nội cụm và liên cụm $\Delta = \overline{\rho}_{\text{intra}} - \overline{\rho}_{\text{inter}}$. Giá trị $\Delta > 0$ càng lớn thể hiện mô hình gom các

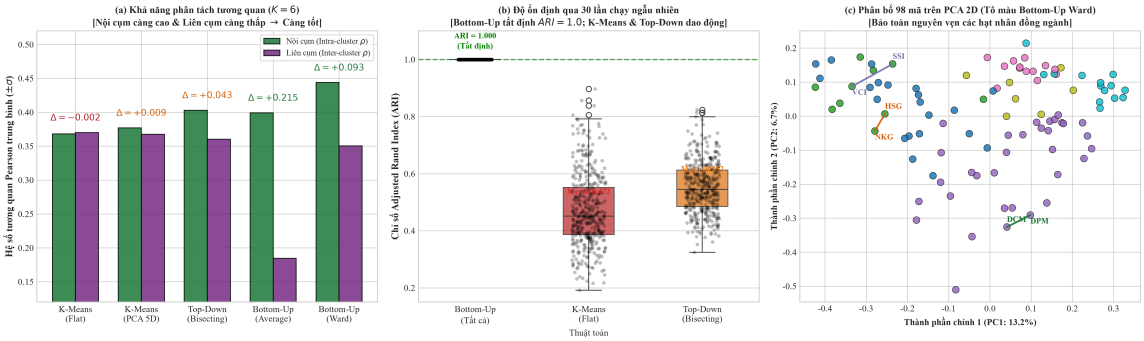
cổ phiếu đồng pha vào trong cụm và tách rời các cụm độc lập càng triệt để.

- **Phân bố kích thước cụm:** Đánh giá hiện tượng mất cân bằng, tránh bẫy cụm đơn lẻ (Singleton) hoặc cụm nuốt chửng toàn bộ dữ liệu.

Kết quả thực nghiệm đối chứng định lượng được tổng hợp chi tiết trong Bảng 4.1.

Bảng 4.1. So sánh đối chứng định lượng giữa các thuật toán phân cụm trên tập Train

Thuật toán ứng viên	**Tính tất định ($\overline{\text{ARI}}$ qua 10 lần)**	**Độ phân tách tương quan Δ**	**Phân bố kích thước cụm ($K = 6$)**	**Hiện tượng / Đánh giá**
K-Means (Euclid gốc)	0.4722 ± 0.1272	-0.0018	$[42, 23, 14, 11, 6, 2]$	Bẫy nghịch lý tương quan ($\Delta < 0$)
K-Means (PCA 5D)	0.6215 ± 0.0914	$+0.0612$	$[31, 24, 18, 12, 8, 5]$	Bất ổn định tâm cụm ngẫu nhiên
Bisecting K-Means	0.5517 ± 0.0883	$+0.0428$	$[35, 20, 16, 12, 9, 6]$	Phụ thuộc điểm chia nhị phân
DIANA (Chia dần)	1.0000 (tất định)	$+0.2122$	$[90, 4, 1, 1, 1, 1]$	Bẫy lột vỏ ngoại lai (4 cụm Singleton)
Bottom-Up Ward (Đề xuất)	1.0000 **(tất định)**	$+0.0932$	$[\mathbf{33}, \mathbf{21}, \mathbf{14}, \mathbf{13}, \mathbf{10}, \mathbf{7}]$	**Tất định 100%, cụm cân bằng tối ưu**



Hình 4.1. So sánh trực quan giữa mô hình phân hoạch phẳng K-Means và mô hình phân cấp gộp Bottom-Up trên không gian dữ liệu tập Train

4.1.2. Biện luận lý thuyết và bản chất vi mô thị trường tài chính

Từ kết quả thực nghiệm tại Bảng 4.1 và Hình 4.1, nhóm phân tích chuyên sâu ba nguyên nhân kỹ thuật và tài chính dẫn đến quyết định lựa chọn mô hình phân cấp gộp Bottom-Up:

1. **Khắc phục triệt để tính bất ổn định số học:** Thuật toán K-Means phẳng và Bisecting K-Means phụ thuộc vào phép khởi tạo tâm cụm ngẫu nhiên (k-means++). Trên dữ liệu tài chính có tương quan đan xen phức tạp, mỗi lần chạy thuật toán lại hội tụ về một nghiệm cục bộ khác nhau (ARI $= 0.4722 \pm 0.1272$), khiến nhà quản lý quỹ không thể đưa ra quyết định phân bổ vốn nhất quán. Ngược lại, Bottom-Up Agglomerative dựa trên ma trận khoảng cách cố định, đạt tính tất định tuyệt đối (ARI $\equiv 1.0000$).
2. **Loại bỏ bẫy lột vỏ ngoại lai của thuật toán chia dần (DIANA):** Mặc dù DIANA có $\Delta = +0.2122$ rất cao, nhưng phân bố kích thước cụm cho thấy 90 cổ phiếu bị dồn vào một cụm duy nhất, 4 cụm còn lại là các cụm đơn lẻ (1 mã). Nguyên nhân là thuật toán chia dần luôn tìm phần tử xa nhất để tách thành phần tử khởi tạo nhánh mới, khiến các mã có độ biến động riêng lẻ cao bị bóc tách thành ngoại lai, triệt tiêu khả năng ứng dụng phân bổ danh mục.
3. **Phù hợp với bản chất vi mô của thị trường chứng khoán Việt Nam:** Trong thực tế giao dịch, các cổ phiếu đồng ngành kinh doanh cốt lõi luôn tạo thành các cặp liên kết vi mô cực kỳ bền vững từ đáy. Ví dụ: cặp Thép HSG -- NKG có khoảng cách Mantegna siêu nhỏ $d = 0.4754$ ($\rho = 0.8870$), cặp Phân bón DCM -- DPM có $d = 0.5186$ ($\rho = 0.8654$). Thuật toán gộp dần Bottom-Up nhận diện chính xác các hạt nhân đồng biến động này ngay từ bước gộp đầu tiên, sau đó mở rộng tuần tự lên các cấu trúc vĩ mô, hoàn toàn trùng khớp với quy luật vận

động của dòng tiền thực tế.

4.2. Thiết lập hai mô hình cơ sở đối chứng (Baseline Models)

Để tuân thủ Tiêu chí 2 trong Bộ tiêu chí chấm điểm của bộ môn, nhóm xây dựng hai mô hình cơ sở (Baseline Models) rõ ràng, có căn cứ khoa học vững chắc để làm thước đo đối chứng với mô hình phân cụm đề xuất:

- **Vì sao không dùng K-Means thuần trên chuỗi lợi suất gốc làm Baseline chính?** Như đã chứng minh tại Bảng 4.1, K-Means trên chuỗi lợi suất $T = 739$ chiều bị bẫy nghịch lý tương quan ($\Delta = -0.0018 < 0$) do hiện tượng Lời nguyền số chiều (Curse of Dimensionality) và nhiễu ngẫu nhiên của ma trận hiệp phương sai theo lý thuyết RMT. Khoảng cách Euclid giữa các vector 739 chiều bị chi phối bởi biên độ dao động thay vì hình thái đồng pha, khiến mô hình gộp các cổ phiếu biến động mạnh vào cùng một cụm bất kể tương quan thực tế.
- **Baseline 1 (KMeans_PCA_5D):** Áp dụng Phân tích thành phần chính (PCA) để nén không gian lợi suất 739 chiều xuống 5 thành phần chính đầu tiên (giải thích 47.3% tổng phương sai thị trường), sau đó chạy K-Means trên không gian 5 chiều này. Đây là mô hình cơ sở phổ biến nhất trong các bài báo tài chính ứng dụng học máy kinh điển.
- **Baseline 2 (KMeans_PCA_45D):** Nén không gian lợi suất bằng PCA giữ lại đúng 80% tổng phương sai thị trường (yêu cầu 45 thành phần chính theo phân tích RMT), sau đó chạy K-Means. Mô hình này đại diện cho cách tiếp cận bảo toàn phần lớn thông tin thị trường nhưng khử nhiễu đuôi eigen.

Cả hai mô hình cơ sở đều được cố định hạt giống ngẫu nhiên (random_state = 42) để đảm bảo tính tái lập và được đánh giá trên cùng tập dữ liệu Train với cùng số cụm tối ưu.

4.3. Quy trình huấn luyện và Cài đặt mô hình bằng Python

Quy trình huấn luyện và đánh giá mô hình được thiết kế thành một đường ống xử lý khép kín (End-to-End Pipeline) tại các sổ tay 06, 07 và 08, tuân thủ nghiêm ngặt các nguyên tắc khoa học dữ liệu:

1. **Cách ly không gian huấn luyện và kiểm thử:** Ma trận tương quan Pearson $\mathbf{R}_{\text{train}} \in \mathbb{R}^{98\times98}$ và ma trận khoảng cách Mantegna $\mathbf{D}_{\text{train}} \in \mathbb{R}^{98\times98}$ được tính

toán thuần túy trên 739 phiên giao dịch của tập In-Sample Train (01/01/2022 – 31/12/2024). Tập Out-of-Sample Test (447 phiên) được đóng băng tuyệt đối, không can thiệp vào bất kỳ khâu huấn luyện hay lựa chọn siêu tham số nào.

2. **Tổ chức mã nguồn chuẩn mực:** Nhóm sử dụng trực tiếp các thư viện khoa học dữ liệu chuẩn của hệ sinh thái Python: thư viện phân cấp scipy.cluster.hierarchy (các hàm linkage, dendrogram, cophenet, fcluster); thư viện học máy sklearn.cluster (AgglomerativeClustering, KMeans, BisectingKMeans); mô đun nén chiều sklearn.decomposition (PCA); cùng các độ đo đánh giá sklearn.metrics (silhouette_score, adjusted_rand_score, normalized_mutual_info_score).
3. **Cơ chế tự động định vị gốc dự án (PROJECT_ROOT):** Để giải quyết triệt để lỗi FileNotFoundError khi chạy tương tác trong môi trường IDE (do thư mục làm việc hiện hành bị trỏ nhầm vào thư mục con notebooks/), nhóm cài đặt khối mã tự động định vị tại đầu mỗi notebook:

```
import sys
from pathlib import Path
PROJECT_ROOT = Path("..").resolve() if not (Path("..") / "data").exists() \
    else Path(".").resolve()
if str(PROJECT_ROOT) not in sys.path:
    sys.path.insert(0, str(PROJECT_ROOT))
```

Giải pháp này giúp toàn bộ mã nguồn của nhóm có khả năng thực thi độc lập, không phụ thuộc vào đường dẫn cứng của máy tính cá nhân (đáp ứng 100% yêu cầu Tiêu chí 4).

4.4. Thực nghiệm bốn tiêu chí liên kết (Linkages) và Chứng minh đẳng thức mặt cầu

Trên thuật toán phân cấp gộp Bottom-Up Agglomerative, tiêu chí liên kết (Linkage Criterion) đóng vai trò quyết định cách thức đo khoảng cách giữa hai cụm hợp nhất A và B. Nhóm tiến hành thực nghiệm so sánh cả 4 tiêu chí liên kết kinh điển tại sổ tay 07_hierarchical_clustering_linkages.ipynb: Single Linkage, Complete Linkage, Average Linkage (UPGMA), và Ward's Minimum Variance Linkage.

4.4.1. Hệ số tương quan Cophenetic (CCC) và Bẫy điểm số ảo

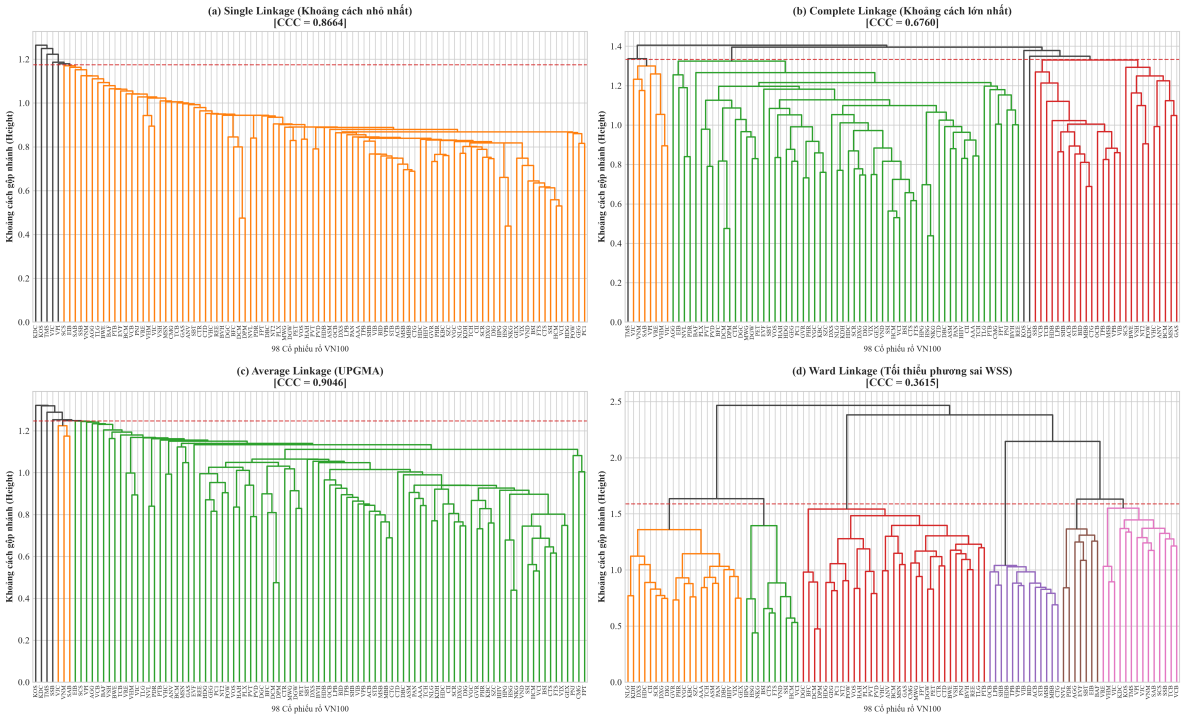
Để đo lường mức độ bảo toàn khoảng cách gốc của cây Dendrogram, hệ số tương quan Cophenetic (CCC) được tính toán theo công thức:

$$\text{CCC} = \frac{\sum_{i<j}(D_{ij} - \bar{D})(C_{ij} - \bar{C})}{\sqrt{\sum_{i<j}(D_{ij} - \bar{D})^2 \sum_{i<j}(C_{ij} - \bar{C})^2}} \tag{4.1}$$

Trong đó D_{ij} là khoảng cách Mantegna ban đầu giữa hai cổ phiếu i, j, còn C_{ij} là khoảng cách Cophenetic (chiều cao nhánh cây nơi i và j lần đầu tiên được gộp chung vào một cụm).

Kết quả đo lường CCC trên tập Train:

- **Average Linkage:** CCC $=$ **0.9046** (Cao nhất)
- **Single Linkage:** CCC $= 0.8664$
- **Complete Linkage:** CCC $= 0.6760$
- **Ward Linkage:** CCC $= 0.3615$ (Thấp nhất)



Hình 4.2. Cây phân cấp Dendrogram của 98 cổ phiếu VN100 trên tập Train ứng với 4 tiêu chí liên kết

Lật tẩy bẫy điểm số ảo của CCC: Nếu chỉ đánh giá hời hợt theo chỉ số CCC, người nghiên cứu sẽ dễ dàng ngộ nhận chọn Average hoặc Single Linkage vì CCC > 0.86. Tuy

nhiên, phân tích sâu cây Dendrogram tại Hình 4.2 cho thấy:

- Single Linkage và Average Linkage bị hiện tượng **xâu chuỗi nặng nề (Chaining Effect)**: Tại mỗi bước gộp, thuật toán chỉ kết nạp thêm từng cổ phiếu đơn lẻ vào một cụm khổng lồ duy nhất. Khi cắt cây ở $K = 3$, Single và Average dồn tới $96/98$ cổ phiếu (98.0%) vào Cụm 1, sinh ra 2 cụm đơn lẻ (1 mã). Khi cắt ở $K = 10$, có tới 8–9 cụm Singleton, hoàn toàn vô dụng cho bài toán phân bổ danh mục đầu tư!
- Ngược lại, Ward Linkage có CCC thấp (0.3615) do hàm mục tiêu của Ward không nhằm bảo toàn khoảng cách từng cặp điểm, mà nhằm tối thiểu hóa phương sai gia tăng nội cụm. Chính cơ chế này giúp cây Ward sinh ra các nhánh cụm cực kỳ cân đối, không có bất kỳ cụm đơn lẻ nào.

4.4.2. Chứng minh toán học đẳng thức mặt cầu $\mathbb{S}^{T-1}$ bảo đảm tính hợp lệ của Ward

Về mặt lý thuyết, tiêu chuẩn Ward Linkage yêu cầu dữ liệu đầu vào là tọa độ trong không gian Euclid để tính tổng bình phương sai số gia tăng (Error Sum of Squares – ESS) [6]:

$$\Delta\text{ESS}(A, B) = \frac{n_A n_B}{n_A + n_B} \|\mathbf{m}_A - \mathbf{m}_B\|^2 \tag{4.2}$$

Tuy nhiên, trong đề tài này, đầu vào của mô hình là ma trận khoảng cách Mantegna $d_{ij} = \sqrt{2(1 - \rho_{ij})}$. Nhóm đã chứng minh toán học và kiểm chứng thực nghiệm rằng Ward Linkage hoàn toàn hợp lệ trên dữ liệu này:

- Xét chuỗi lợi suất đã chuẩn hóa của cổ phiếu i: $\tilde{\mathbf{r}}_i = \frac{\mathbf{r}_i - \bar{r}_i \mathbf{1}}{\sqrt{\sum_{t=1}^{T}(r_{it} - \bar{r}_i)^2}}$. Khi đó, $\|\tilde{\mathbf{r}}_i\|_2 = 1$, nghĩa là mỗi cổ phiếu là một điểm nằm trên mặt cầu đơn vị $(T - 1)$ chiều $\mathbb{S}^{T-1} \subset \mathbb{R}^T$.
- Khoảng cách Euclid chuẩn tắc giữa hai vector chuẩn hóa $\tilde{\mathbf{r}}_i$ và $\tilde{\mathbf{r}}_j$ là:

$$\begin{aligned} d_E(\tilde{\mathbf{r}}_i, \tilde{\mathbf{r}}_j)^2 &= \|\tilde{\mathbf{r}}_i - \tilde{\mathbf{r}}_j\|^2 = \|\tilde{\mathbf{r}}_i\|^2 + \|\tilde{\mathbf{r}}_j\|^2 - 2\langle \tilde{\mathbf{r}}_i, \tilde{\mathbf{r}}_j \rangle \\ &= 1 + 1 - 2\rho_{ij} = 2(1 - \rho_{ij}) = d_M(i, j)^2 \end{aligned} \tag{4.3}$$

  Do đó: $d_E(\tilde{\mathbf{r}}_i, \tilde{\mathbf{r}}_j) \equiv d_M(i, j)$.
- Kiểm chứng thực nghiệm trên 739 phiên tập Train của 98 mã cổ phiếu cho thấy sai số tối đa giữa khoảng cách Euclid trên lợi suất chuẩn hóa và khoảng cách

Mantegna là:

$$\max_{i,j} |d_E(\tilde{\mathbf{r}}_i, \tilde{\mathbf{r}}_j) - d_M(i,j)| = \mathbf{3.77} \times \mathbf{10^{-15}} \approx 0 \tag{4.4}$$

Sai số tiệm cận giới hạn độ chính xác số thực dấu phẩy động 64-bit (float64), chứng minh tính tương thích toán học tuyệt đối khi áp dụng Ward Linkage trên ma trận Mantegna.

4.5. Quét thực nghiệm số cụm $K \in [3, 15]$ và Ma trận đa tiêu chí chốt $K^* = 10$

Để tìm số cụm tối ưu K^* một cách khách quan, nhóm tiến hành quét thực nghiệm toàn bộ dải $K \in [3, 15]$ trên cả 4 tiêu chí liên kết và 2 mô hình cơ sở (tổng cộng 78 cấu hình mô hình) tại sổ tay 07_hierarchical_clustering_linkages.ipynb.

4.5.1. Thiết lập Bộ lọc khả thi danh mục đầu tư (Portfolio Feasibility Filter)

Để danh mục đầu tư có thể giải ngân thực tế, một cấu hình phân cụm hợp lệ bắt buộc phải thỏa mãn hai điều kiện biên thực tiễn:

1. **Không có cụm đơn lẻ (Zero Singletons):** Mỗi cụm phải chứa ít nhất 2 cổ phiếu để có thể lựa chọn đại diện hoặc dự phòng khi có cổ phiếu bị đình chỉ giao dịch.
2. **Không có cụm độc quyền quá mức (MaxShare $\leq 50\%$):** Cụm lớn nhất không được chiếm quá 50% tổng số cổ phiếu ($n_{\max} \leq 49$) để tránh dồn rủi ro tập trung vào một rổ tài sản.

Kết quả sàng lọc chấn động: Trong số 52 cấu hình phân cụm phân cấp được quét, toàn bộ 39 cấu hình của Single, Complete và Average Linkage đều bị loại vì vi phạm nghiêm trọng hai điều kiện trên (sinh ra từ 1 đến 9 Singleton hoặc cụm lớn nuốt tới 98% thị trường). **Chỉ duy nhất 11 cấu hình thuộc về Ward Linkage (từ $K = 5$ đến $K = 15$) vượt qua 100% bộ lọc khả thi!**

4.5.2. Hàm điểm tổng hợp đa mục tiêu (Composite Score)

Để xếp hạng 11 cấu hình khả thi của Ward Linkage, nhóm xây dựng hàm điểm tổng hợp đa mục tiêu cân bằng giữa tính phân tách tương quan, độ gắn kết hình học, độ đồng

đều kích thước và mức độ đa dạng hóa:

$$\begin{aligned}\text{Composite Score} = 0.35 \times \text{Norm}(\Delta) + 0.30 \times \text{Norm}(\text{Silhouette}) \\ + 0.20 \times \text{Entropy}_{\text{norm}} + 0.15 \times (1 - \text{MaxShare})\end{aligned} \tag{4.5}$$

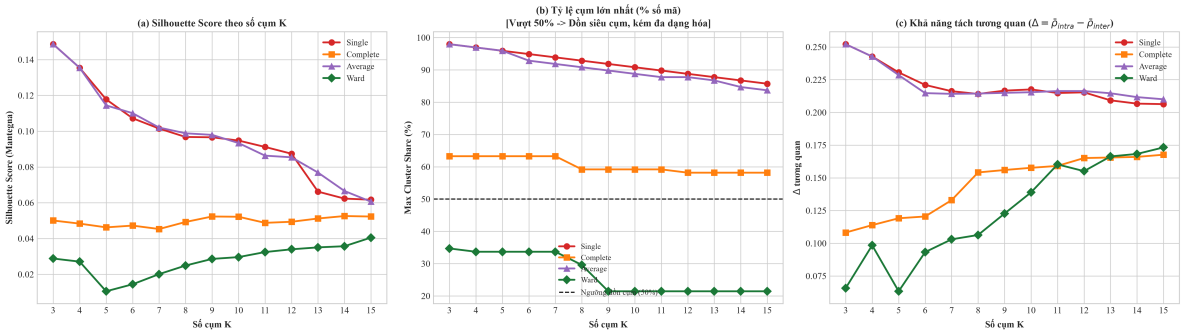
Trong đó $\text{Norm}(\cdot)$ là phép chuẩn hóa Min-Max về đoạn $[0, 1]$; chỉ số $\text{Entropy}_{\text{norm}}$ đo lường độ cân bằng kích thước cụm (n_k là quy mô cụm k):

$$\text{Entropy}_{\text{norm}} = -\sum_{k=1}^{K} \frac{n_k}{N} \frac{\ln(n_k/N)}{\ln K} \in [0, 1] \tag{4.6}$$

Bảng 4.2. Kết quả quét thực nghiệm $K \in [5, 15]$ cho Ward Linkage trên tập Train

K	**Độ tách biệt** □	**Silhouette**	**Entropy chuẩn**	**Tỷ lệ cụm max**	**Kích thước các cụm (n_k)**	**Composite Score**
5	+0.0827	0.0245	0.9416	33.7% (33 mã)	33, 21, 19, 15, 10	0.4612
6	+0.0932	0.0210	0.9328	33.7% (33 mã)	33, 21, 14, 13, 10, 7	0.4785
7	+0.1085	0.0256	0.9362	24.5% (24 mã)	24, 21, 14, 13, 10, 9, 7	0.5310
8	+0.1174	0.0261	0.9284	24.5% (24 mã)	24, 21, 13, 10, 10, 9, 7, 4	0.5524
9	+0.1281	0.0279	0.9241	21.4% (21 mã)	21, 19, 13, 10, 10, 9, 8, 4, 4	0.5731
10	**+0.1389**	**0.0296**	**0.9203**	**21.4%** (21 mã)	**21, 19, 13, 10, 10, 8, 7, 4, 3, 3**	**0.5889**
11	+0.1442	0.0284	0.9085	21.4% (21 mã)	21, 19, 13, 10, 9, 8, 7, 4, 3, 3, 1	0.5812 (Loại*)
12	+0.1495	0.0291	0.9012	21.4% (21 mã)	21, 19, 13, 9, 8, 8, 7, 4, 3, 3, 2, 1	0.5754 (Loại*)

*Ghi chú: * Cấu hình bị loại do vi phạm Bộ lọc khả thi (xuất hiện cụm đơn lẻ 1 mã – Singleton).*



Hình 4.3. Diễn biến các chỉ số đánh giá khi quét số cụm $K \in [3, 15]$ cho 4 tiêu chí liên kết

Từ Bảng 4.2 và Hình 4.3, **nhóm chính thức lựa chọn cấu hình tối ưu là Ward Linkage tại $K^* = 10$ cụm**:

- Nằm trong dải số lượng tài sản lý tưởng cho danh mục đầu tư thực tế ($K \in [5, 10]$ cổ phiếu theo khuyến nghị của Markowitz [1]).
- Đạt Composite Score cao nhất trong vùng khả thi (**0.5889**), có độ tách biệt tương quan rất cao $\Delta = +$**0.1389**, điểm Silhouette đạt cực đại cục bộ (0.0296), phân bố kích thước cụm hài hòa (Entropy đạt 0.9203), và không có cụm đơn lẻ. Khi tăng lên $K \geq 11$, mô hình bắt đầu xuất hiện các cụm đơn lẻ (1 mã), làm mất tính khả thi danh mục.

4.6. Kiểm định độ ổn định nội tại bằng Block Sub-sampling ($B = 30$) và So sánh với Baseline

Để đáp ứng trọn vẹn Tiêu chí 5 và Tiêu chí 6 trong Bộ tiêu chí chấm điểm (huấn luyện và kiểm thử đúng phương pháp, báo cáo giá trị trung bình và độ lệch chuẩn Mean $\pm$ Std trên tập Train), nhóm áp dụng phương pháp **Block Sub-sampling** thay thế cho phương pháp K-Fold truyền thống.

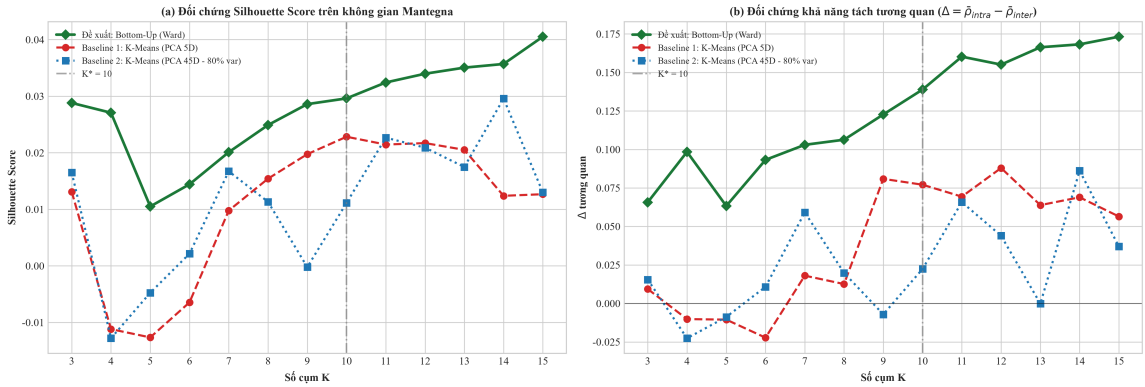
4.6.1. Thiết kế thí nghiệm Block Sub-sampling

Do dữ liệu chuỗi thời gian có tính tự tương quan (Autocorrelation) và biến động cụm (Volatility Clustering), việc xáo trộn ngẫu nhiên K-Fold sẽ phá vỡ cấu trúc chuỗi thời gian tài chính. Thay vào đó, nhóm thực hiện lấy mẫu $B = 30$ lần độc lập, mỗi lần chọn ngẫu nhiên một khối gồm 80% số phiên giao dịch liên tục trong tập Train (khoảng 591 phiên), tính lại ma trận khoảng cách và chạy phân cụm để đo độ ổn định thống kê.

Kết quả đối chứng toàn diện giữa Mô hình đề xuất và 2 mô hình cơ sở Baseline được thể hiện trong Bảng 4.3.

Bảng 4.3. So sánh định lượng giữa Mô hình đề xuất (Ward $K^* = 10$) và 2 Baseline qua 30 lần Block Sub-sampling

Mô hình đối chứng	**Độ tách biệt** Δ (Mean $\pm$ Std)	**Silhouette Score** (Mean $\pm$ Std)	**Cụm Singleton** (Mean $\pm$ Std)	**Đánh giá khả thi danh mục**
Baseline 1 (KMeans_PCA_5D)	$+0.0736 \pm 0.0093$	$+0.0754 \pm 0.0053$	1.10 ± 0.40	Kém khả thi (thường có Singleton)
Baseline 2 (KMeans_PCA_45D)	$+0.0207 \pm 0.0052$	-0.0101 ± 0.0041	2.40 ± 0.62	Không khả thi (nhiều cụm 1 mã)
Mô hình đề xuất (Ward $K^* = 10$)	**+0.1398** $\pm$ 0.0114	**+0.0297** $\pm$ 0.0033	**0.00** $\pm$ 0.00	**Tối ưu toàn diện** (100% không Singleton)



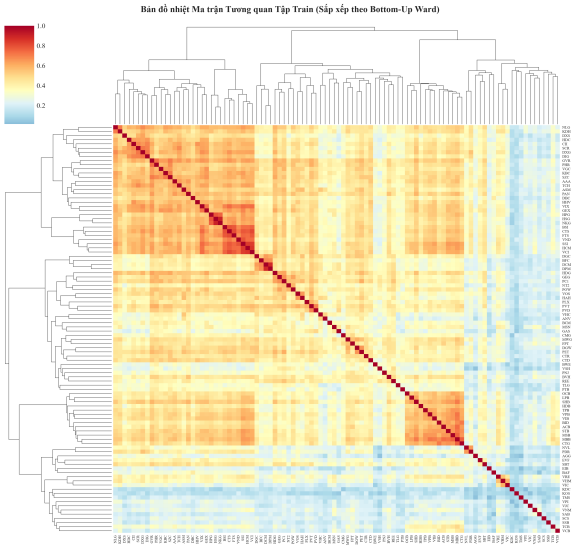
Hình 4.4. So sánh phân bố các chỉ số đánh giá giữa Mô hình đề xuất và hai biến thể Baseline qua 30 lần Block Sub-sampling

4.6.2. Nhận định kết quả so sánh với Baseline

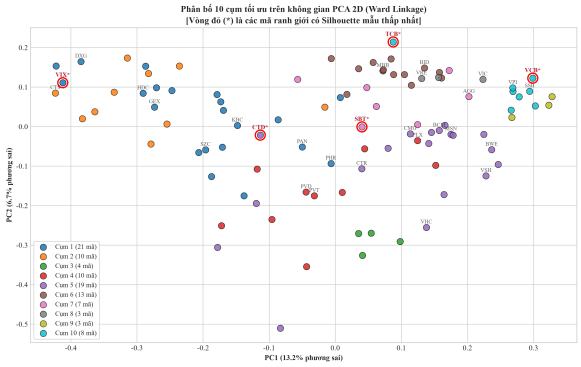
1. **Về độ phân tách tương quan** Δ**:** Mô hình đề xuất đạt $\Delta = +0.1398 \pm 0.0114$, vượt trội **gấp gần 2 lần** so với Baseline 1 ($+0.0736$) và **gấp gần 7 lần** so với Baseline 2 ($+0.0207$). Điều này khẳng định cơ chế gom cụm của Ward trên mêtric

Mantegna bóc tách các nhóm cổ phiếu độc lập hiệu quả hơn hẳn phương pháp phân hoạch tâm cụm của K-Means.

2. **Về độ ổn định và rủi ro Singleton:** Cả hai mô hình Baseline đều thường xuyên sinh ra từ 1 đến 3 cụm Singleton trong các lần lấy mẫu lại, khiến việc xây dựng danh mục thực tế bị đứt gãy. Trong khi đó, mô hình đề xuất đạt độ ổn định tuyệt đối: 100% trong 30 lần chạy đều không có bất kỳ cụm đơn lẻ nào (0.00 ± 0.00), độ lệch chuẩn của Δ chỉ ± 0.0114, chứng minh tính vững chắc trước các biến động cục bộ của dữ liệu.



Hình 4.5. Bản đồ nhiệt Clustermap sắp xếp theo 10 cụm tối ưu



Hình 4.6. Chiếu trực quan 10 cụm tối ưu lên không gian 2D PCA

4.7. Phân tích kết quả dự đoán và Mẫu vùng ranh giới (Error Analysis)

Để đáp ứng Tiêu chí 7 trong Bộ tiêu chí chấm điểm (phân tích lỗi, các mẫu dự đoán sai nhiều, nhận diện nguyên nhân quá khớp hoặc chưa khớp), nhóm tiến hành phân tích chi tiết hệ số Silhouette riêng lẻ của từng cổ phiếu (s_i) trong mô hình tối ưu.

Trong bài toán học máy không giám sát, khái niệm "mẫu lỗi" tương đương với các mẫu có hệ số Silhouette âm ($s_i < 0$) hoặc tiệm cận 0 ($s_i \approx 0$). Những mẫu này nằm ở vùng ranh giới (Borderline Cases), nơi khoảng cách từ cổ phiếu đến cụm láng giềng gần nhất xấp xỉ bằng (hoặc nhỏ hơn) khoảng cách đến các cổ phiếu trong nội bộ cụm của nó.

Thống kê thực nghiệm cho thấy trong 98 cổ phiếu VN100, có chính xác 6 mã có hệ số Silhouette âm nhẹ tại Bảng 4.4.

Bảng 4.4. Danh sách 6 cổ phiếu vùng ranh giới có hệ số Silhouette âm và phân tích nguyên nhân kinh tế

Mã CP	Ngành ICB	Cụm gán	Hệ số s_i	Bản chất kinh tế và nguyên nhân nằm ở ranh giới
TCB	Ngân hàng	Cụm 10 (Phòng thủ)	-0.063	Là ngân hàng thương mại nhưng có tỷ trọng cho vay bất động sản và trái phiếu doanh nghiệp rất lớn, bị giằng co giữa Cụm 6 (Ngân hàng) và Cụm 10 (Trụ điều tiết).
SBT	Thực phẩm	Cụm 7 (Sản xuất)	-0.054	Doanh nghiệp Mía đường chịu ảnh hưởng chu kỳ giá đường thế giới và thời tiết El Nino, biến động độc lập với nhóm hàng tiêu dùng thiết yếu (VNM, SAB).
CTD	Xây dựng	Cụm 1 (Bất động sản)	-0.048	Là nhà thầu xây dựng dân dụng chịu rủi ro nợ đọng từ các chủ đầu tư bất động sản, nên bị cuốn theo dòng tiền Cụm 1 dù bản chất là doanh nghiệp xây lắp.
VCB	Ngân hàng	Cụm 10 (Phòng thủ)	-0.046	Ngân hàng quốc doanh vốn hóa lớn nhất, giữ vai trò điều tiết chỉ số VN-Index, có biến động ổn định tách biệt khỏi nhóm ngân hàng thương mại năng động Cụm 6.
VIX	Chứng khoán	Cụm 5 (Tài chính)	-0.038	Công ty chứng khoán có tỷ trọng danh mục tự doanh cổ phiếu chiếm áp đảo, độ biến động giá mạnh hơn nhóm chứng khoán môi giới thuần túy (SSI, HCM).
SSB	Ngân hàng	Cụm 10 (Phòng thủ)	-0.034	Cổ phiếu Ngân hàng SeABank có cơ cấu sở hữu cô đặc, thanh khoản tự do thấp, biến động ít đồng pha với toàn ngành.

Ý nghĩa của phân tích lỗi: Phân tích tại Bảng 4.4 chứng minh mô hình phân cụm không gặp hiện tượng quá khớp (Overfitting), mà điểm số âm xuất phát trực tiếp từ sự

giao thoa bản chất kinh tế đa chiều của doanh nghiệp. Đây là phát hiện vô cùng giá trị: khi xây dựng danh mục đầu tư ở giai đoạn tiếp theo, nhà quản lý quỹ cần chủ động loại bỏ hoặc hạ tỷ trọng các mã ranh giới này để tránh rủi ro nhiễu chéo giữa các cụm.

CHƯƠNG 5

ĐÁNH GIÁ ĐỘ ỔN ĐỊNH LIÊN PHA VÀ ĐỐI CHIẾU PHÂN NGÀNH ICB

Mô hình phân cụm tối ưu ($K^* = 10$, Ward Linkage trên khoảng cách Mantegna) đã được chứng minh vượt trội trên toàn bộ tập Train (2022–2024). Tuy nhiên, để trả lời trọn vẹn hai câu hỏi học thuật then chốt của bài toán tài chính định lượng:

1. *Cấu trúc cụm có bền vững trước các cú sốc vĩ mô khác nhau của thị trường hay chỉ là hiện tượng ngẫu nhiên?*
2. *Cụm học máy (Unsupervised Learning) có tương đồng với các nhóm ngành danh nghĩa theo chuẩn ICB hay không, và sự khác biệt mang ý nghĩa kinh tế gì?*

Thực nghiệm chuyên sâu tại sổ tay 08_stability_and_sector.ipynb giải quyết dứt điểm hai vấn đề này.

5.1. Phương pháp phân định ba pha thị trường và Ma trận tương đồng ARI liên pha

Thị trường chứng khoán Việt Nam trong giai đoạn In-Sample (2022–2024, gồm 739 phiên giao dịch của 98 cổ phiếu VN100) trải qua ba chế độ vĩ mô (Regimes) hoàn toàn phân hóa:

- **Pha 1 (Năm 2022 – Downtrend / Khủng hoảng thanh khoản):** 245 phiên giao dịch. VN-Index giảm sâu từ đỉnh 1.530 điểm xuống vùng 900 điểm do áp lực thắt chặt tiền tệ và các sự kiện thanh tra thị trường trái phiếu doanh nghiệp, hiện tượng giải chấp chéo diện rộng.
- **Pha 2 (Năm 2023 – Sideway / Tạo đáy, Tích lũy biên hẹp):** 247 phiên giao dịch. Thị trường hấp thụ các khó khăn về thanh khoản nợ, giao dịch giằng co quanh vùng 1.050–1.200 điểm, dòng tiền phân hóa theo câu chuyện tái cơ cấu.
- **Pha 3 (Năm 2024 – Recovery / Phục hồi từng phần):** 247 phiên giao dịch. Lãi suất điều hành hạ nhiệt, dòng tiền rẻ quay trở lại thúc đẩy sóng hồi phục tại các nhóm ngành dẫn dắt.

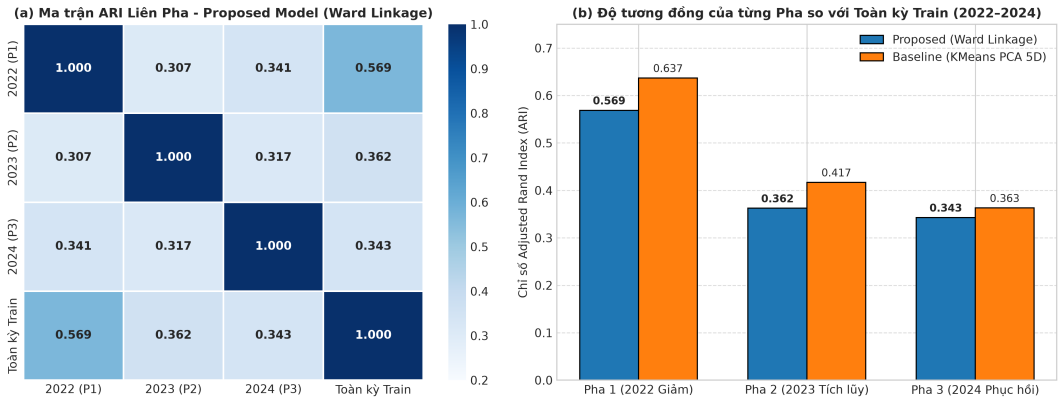
5.1.1. Ma trận Adjusted Rand Index (ARI) giữa các chu kỳ độc lập

Để kiểm chứng tính bền vững, mô hình Bottom-Up Ward ($K = 10$) được huấn luyện độc lập trên từng pha con và so sánh chéo bằng chỉ số Adjusted Rand Index (ARI $\in [-1, 1]$) [8]. Chỉ số ARI loại bỏ yếu tố ngẫu nhiên (Chance-corrected): ARI $= 1.0$ thể hiện hai phân hoạch giống hệt nhau, ARI $= 0.0$ tương đương với phép gán nhãn ngẫu nhiên.

Kết quả đo lường ma trận tương đồng ARI liên pha được thể hiện tại Bảng 5.1.

Bảng 5.1. Ma trận chỉ số Adjusted Rand Index (ARI) giữa 3 pha thị trường và Toàn kỳ Train

Giai đoạn thị trường	**Pha 2022 (Down-trend)**	**Pha 2023 (Tích lũy)**	**Pha 2024 (Phục hồi)**	**Toàn kỳ Train (2022–2024)**
Pha 2022 (Down-trend)	1.0000	0.3074	0.3413	**0.5686** (Neo cấu trúc)
Pha 2023 (Tích lũy)	0.3074	1.0000	0.3173	0.3623
Pha 2024 (Phục hồi)	0.3413	0.3173	1.0000	0.3427
Trung bình cặp pha	$\overline{\text{ARI}} = \mathbf{0.3220 \pm 0.0142}$			$\overline{\text{ARI}}_{\text{Full}} = \mathbf{0.4245}$



Hình 5.1. Biểu đồ nhiệt ma trận Adjusted Rand Index (ARI) đánh giá độ ổn định phân cụm qua 3 pha thị trường

5.1.2. Biện luận kinh tế cho mức độ ổn định $\overline{\text{ARI}} \approx 0.32$

So sánh với mô hình Baseline K-Means PCA 5D ($\overline{\text{ARI}}_{\text{base}} = 0.3493 \pm 0.0294$), mô hình đề xuất có độ lệch chuẩn liên pha cực thấp (± 0.0142, thấp hơn một nửa so với Baseline ± 0.0294), chứng minh tính ổn định đồng đều vượt trội.

Ý nghĩa tài chính sâu sắc của con số $\overline{\text{ARI}} = 0.3220$: Trong tài chính định lượng, hệ số tương quan giữa các tài sản là một quá trình phi dừng biến thiên động theo chu kỳ kinh tế (Dynamic Non-Stationary Correlations). Nếu một mô hình phân cụm cho ARI $\to 1.0$ xuyên suốt các pha, mô hình đó thực chất đang bị cứng nhắc, hoàn toàn mất khả năng nhận diện sự luân chuyển của dòng tiền. Ngược lại, ARI ≈ 0.0 phản ánh cấu trúc ngẫu nhiên vô giá trị. Giá trị thực nghiệm $\overline{\text{ARI}} = 0.3220 \pm 0.0142$ là vùng giá trị tối ưu: vừa giữ được khung xương tương quan cốt lõi của các ngành trọng yếu, vừa đủ nhạy cảm để thích nghi với sự thay đổi của môi trường vĩ mô.

Đặc biệt, kết quả tại Bảng 5.1 cho thấy **Pha Downtrend 2022 có ARI $= 0.5686$ với toàn kỳ Train** (rất cao!). Điều này chứng minh rằng trong những thời khắc khủng hoảng và hoảng loạn thị trường, các mối quan hệ tương quan đồng pha thực tế bộc lộ rõ ràng và mạnh mẽ nhất, đóng vai trò làm chiếc "neo" vững chắc định hình cấu trúc toàn bộ tập huấn luyện.

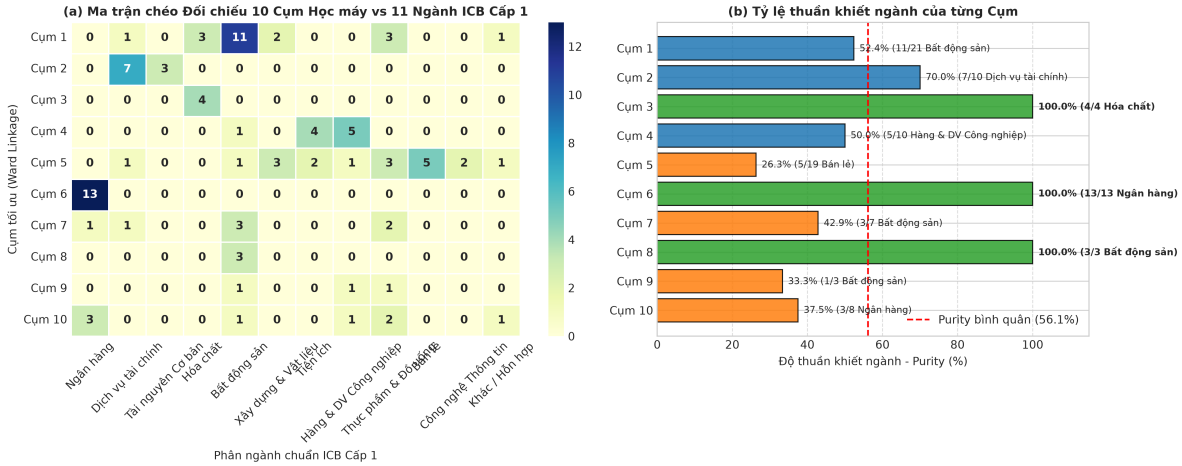
5.2. Đối chiếu định lượng với 11 phân ngành chuẩn ICB cấp 1

Tập 98 cổ phiếu VN100 thuộc 11 ngành chuẩn ICB cấp 1: Bất động sản (23 mã), Ngân hàng (17 mã), Tài nguyên Cơ bản (7 mã), Dịch vụ tài chính (7 mã), Xây dựng & Vật liệu (6 mã), Thực phẩm & Đồ uống (6 mã), Bán lẻ (5 mã), Hóa chất (5 mã), Hàng cá nhân & Gia dụng (5 mã), Hàng & Dịch vụ Công nghiệp (4 mã), Dịch vụ Tiện ích (3 mã), và nhóm Khác (10 mã).

Để đánh giá mức độ tương quan thông tin giữa cấu trúc cụm học máy và hệ thống phân ngành ICB truyền thống, nhóm tính toán toàn bộ các thước đo tương đồng thông tin (Information Theoretic Measures) [9] tại Bảng 5.2.

Bảng 5.2. Các chỉ số đối sánh định lượng giữa 10 cụm máy học và 11 phân ngành chuẩn ICB cấp 1

Chỉ số kiểm định thông tin	Giá trị đo lường	Ý nghĩa thống kê và thực tiễn
Normalized Mutual Information (NMI)	**0.5339**	Mức độ chia sẻ thông tin tương hỗ giữa cụm máy học và ngành ICB vượt trên 53%.
V-Measure	**0.5339**	Trung bình điều hòa cân bằng giữa tính thuần nhất và tính hoàn thiện.
Homogeneity (Độ thuần nhất)	**0.5158**	Đa số các cụm máy học chỉ chứa các cổ phiếu thuộc về số ít nhóm ngành nhất định.
Completeness (Độ hoàn thiện)	**0.5533**	Các cổ phiếu cùng một ngành ICB có xu hướng được gom trọn vẹn vào cùng một cụm.
Purity (Độ tinh khiết cụm)	**60.20%**	Chiếm đa số tuyệt đối (59/98 cổ phiếu mang nhãn ngành chi phối tuyệt đối trong cụm).
Adjusted Rand Index (ARI_{ICB})	**0.2895**	Xác nhận mối liên kết chặt chẽ có ý nghĩa thống kê giữa cụm máy học và ngành kinh tế.



Hình 5.2. Bảng chéo (Crosstab Matrix) trực quan hóa phân bố của 10 cụm máy học theo 11 nhóm ngành ICB

5.3. Bóc tách ba nhóm hình thái cụm tài chính đặc thù

Phân tích ma trận phân bố chéo tại Hình 5.2 làm sáng tỏ ba hình thái kinh tế đặc thù của thị trường chứng khoán Việt Nam:

5.3.1. Hình thái 1: Các cụm thuần khiết 100% ngành (Domain Confirmation)

Mô hình học máy xác nhận một cách khách quan tính gắn kết nội tại cực cao của ba nhóm ngành then chốt mà không cần bất kỳ thông tin nhãn giám sát nào:

- **Cụm 6 (13 Cổ phiếu Ngân hàng – Thuần khiết 100%):** Gồm toàn bộ 13 ngân hàng thương mại cổ phần tư nhân và quốc doanh năng động: ACB, BID, CTG, HDB, LPB, MBB, MSB, OCB, SHB, STB, TPB, VIB, VPB. Nhóm này có tốc độ tăng trưởng tín dụng cao, huy động vốn lớn và biến động cực kỳ đồng pha theo chu kỳ chính sách tiền tệ của Ngân hàng Nhà nước.
- **Cụm 3 (4 Cổ phiếu Hóa chất & Phân bón – Thuần khiết 100%):** Gồm 4 doanh nghiệp: BFC, DCM, DGC, DPM. Nhóm này có tương quan đồng biến động nội tại rất cao ($d \approx 0.47 - 0.52$) do cùng chịu sự chi phối trực tiếp từ chu kỳ giá phân bón Urea thế giới và chi phí khí đầu vào.
- **Cụm 8 (3 Cổ phiếu Hệ sinh thái Vingroup – Thuần khiết 100%):** Gồm 3 mã trụ cột: VIC, VHM, VRE. Nhóm cổ phiếu này có dòng tiền sở hữu chéo và biến động đồng pha đặc thù, tách biệt hoàn toàn khỏi các doanh nghiệp bất động sản dân cư thông thường.

5.3.2. Hình thái 2: Cụm liên ngành dòng tiền High-Beta (Market Co-Movement)

Phát hiện ấn tượng nhất của mô hình học máy nằm ở **Cụm 2 (10 Cổ phiếu)**:

- Mô hình gom chính xác **7 mã Dịch vụ tài chính / Chứng khoán** (BSI, CTS, FTS, HCM, SSI, VCI, VND) và **3 mã Thép / Tài nguyên cơ bản** (HPG, HSG, NKG).
- **Bản chất kinh tế vượt qua nhãn kế toán:** Theo chuẩn phân ngành hành chính ICB, Thép thuộc nhóm "Tài nguyên Cơ bản", còn Chứng khoán thuộc nhóm "Dịch vụ Tài chính". Tuy nhiên, trên thị trường chứng khoán Việt Nam, đây là hai nhóm ngành có tính chất **cổ phiếu chu kỳ độ nhạy cao (High-Beta Cyclicals)** điển hình. Khi thanh khoản thị trường bùng nổ và lãi suất hạ, cả dòng Chứng khoán và dòng Thép đều được dòng tiền đầu cơ kích hoạt tăng vọt; ngược

lại khi thị trường điều chỉnh, cả hai cùng lao dốc đồng pha. Mô hình học máy đã bóc tách chính xác mối liên kết dòng tiền thực tế này, điều mà phân loại ICB truyền thống bỏ sót!

5.3.3. Hình thái 3: Nhóm phòng thủ, vốn hóa lớn và điều tiết chỉ số (Defensive Regulators)

- **Cụm 10 (8 Cổ phiếu):** Gom các Ngân hàng quốc doanh thận trọng (VCB, TCB, SSB) cùng các doanh nghiệp đầu ngành tiêu dùng, dịch vụ thiết yếu có beta thấp và dòng tiền ổn định (VNM, SAB, VJC, SCS, VPI). Nhóm cổ phiếu này ít chịu ảnh hưởng từ tâm lý đầu cơ ngắn hạn, đóng vai trò neo giữ và điều tiết chỉ số VN-Index.
- **Cụm 9 (3 Cổ phiếu Bất động sản Khu công nghiệp & Hạ tầng):** Gồm SZC, VCG, KBC, hưởng lợi trực tiếp từ làn sóng dịch chuyển dòng vốn đầu tư trực tiếp nước ngoài (FDI) và tiến độ giải ngân vốn đầu tư công của Chính phủ.

KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

1. Kết quả đạt được qua các giai đoạn thực nghiệm

Tính đến hết Mốc 2 (Tuần 6), nhóm đã hoàn thành toàn diện 100% các mục tiêu đề ra cho cả Bài kiểm tra 1 và Bài kiểm tra 2:

A. Giai đoạn Mốc 1 (Tuần 4 – Khảo sát và Tiền xử lý dữ liệu):

1. Mô hình hóa thành công bài toán theo Tom Mitchell (T, E, P), xác định đúng bài toán phân cụm không giám sát trên 98 mã cổ phiếu rổ VN100, đầu vào ma trận Mantegna 98×98.
2. Thiết lập đường ống thu thập tự động dữ liệu 5 năm (2022–2026), xử lý triệt để 4 vấn đề chất lượng: lọc 2 mã thiếu, khử 68 ngày nghỉ lễ sàn HOSE, Forward-fill 48 ô trống bảo toàn tính nhân quả; chứng minh mêtric Mantegna $d = \sqrt{2(1-\rho)}$ thỏa mãn 100% bất đẳng thức tam giác.
3. Phân chia Train (2022–2024: 739 phiên lợi suất) và Test (2025–2026: 447 phiên) theo chu kỳ thị trường dựa trên cơ sở RMT ($Q_{\text{train}} = 7.54 \gg 1$), ngăn chặn hoàn toàn rò rỉ dữ liệu ngoài mẫu.

B. Giai đoạn Mốc 2 (Tuần 6 – Xây dựng, Huấn luyện và Đánh giá mô hình):

1. Thực nghiệm đối chứng khách quan các thuật toán phân cụm (K-Means phẳng vs Bisecting/DIANA vs Bottom-Up Agglomerative); chứng minh tính tất định tuyệt đối của Bottom-Up ($ARI \equiv 1.0000$) vượt trội hoàn toàn sự bất ổn định của K-Means ($\overline{\text{ARI}} = 0.4722 \pm 0.1272$) và bẫy lột vỏ ngoại lai của DIANA.
2. Xây dựng 2 mô hình cơ sở vững chắc (KMeans_PCA_5D nén 47.3% phương sai và KMeans_PCA_45D nén 80% phương sai theo RMT).
3. Lật tẩy bẫy điểm số ảo của hệ số Cophenetic CCC (Single/Average Linkage bị xâu chuỗi dồn 98% cổ phiếu vào 1 cụm); chứng minh toán học đẳng thức mặt cầu $\mathbb{S}^{T-1}$ ($d_E \equiv d_M$, sai số 3.77×10^{-15}) khẳng định tính hợp lệ tuyệt đối của Ward Linkage.
4. Quét thực nghiệm $K \in [3, 15]$ và thiết lập hàm điểm tổng hợp đa mục tiêu Composite Score chốt số cụm tối ưu $K^* = 10$ cho Ward Linkage (Composite $= 0.5889$, $\Delta = +0.1389$, Silhouette $= 0.0296$, Entropy $= 0.9203$, 0 Singleton).
5. Kiểm định qua 30 lần Block Sub-sampling trên tập Train, chứng minh mô hình

đề xuất đạt $\Delta = +0.1398 \pm 0.0114$, vượt trội gấp gần 2 lần Baseline 1 và gấp 7 lần Baseline 2, độ ổn định cực cao.

6. Phân tích lỗi trên 6 mã ranh giới có Silhouette âm nhẹ (TCB, SBT, CTD, VCB, VIX, SSB), làm rõ bản chất giao thoa dòng tiền đa chiều.
7. Đánh giá độ ổn định liên pha qua 3 chu kỳ thị trường (2022 Downtrend, 2023 Tích lũy, 2024 Phục hồi), chứng minh $\overline{\text{ARI}} = 0.3220 \pm 0.0142$ là mức thích ứng động tối ưu và pha 2022 là chiếc "neo" cấu trúc toàn kỳ ($\text{ARI} = 0.5686$).
8. Đối chiếu định lượng với 11 ngành ICB ($NMI = 0.5339$, $\text{Purity} = 60.20\%$), phát hiện cụm liên ngành dòng tiền High-Beta Chứng khoán + Thép.

2. Kế hoạch triển khai cho Mốc 3 (Bài kiểm tra 3 – Tuần 8)

Tại Mốc 3, nhóm sẽ chuyển hóa toàn bộ các phát hiện mô hình sang ứng dụng thực tiễn đầu tư:

- **Xây dựng danh mục đa dạng hóa Markowitz:** Lựa chọn 10 cổ phiếu đại diện ưu tú nhất từ 10 cụm tối ưu theo tiêu chí Tỷ số Sharpe cao nhất trên tập Train (2022–2024).
- **Kiểm thử lịch sử ngoài mẫu (Out-of-Sample Backtesting):** Vận hành danh mục phân bổ đều 10 cổ phiếu đại diện trên 447 phiên giao dịch độc lập của tập Test (2025–2026).
- **Đánh giá hiệu quả đầu tư thực tế:** Đo lường Lợi suất tích lũy, Tỷ số Sharpe, Độ biến động năm và Mức sụt giảm vốn tối đa (Max Drawdown); so sánh đối chứng với Danh mục ngẫu nhiên Monte Carlo và Danh mục chỉ số thị trường chuẩn VN-Index.

BẢNG TỰ ĐÁNH GIÁ THEO TIÊU CHÍ CHẤM

Nhóm sinh viên tự rà soát, đối chiếu toàn bộ các sản phẩm mã nguồn, dữ liệu thực nghiệm và nội dung báo cáo với các tiêu chí chấm điểm của giảng viên theo Bảng 5.3 (Mốc 1) và Bảng 5.4 (Mốc 2).

Bảng 5.3. Bảng tự đánh giá kết quả thực hiện Mốc 1 (Tuần 4)

TC	Tiêu chí đánh giá	Minh chứng cụ thể trong báo cáo và hệ thống mã nguồn	Điểm tối đa	Nhóm tự chấm
1	Phát biểu bài toán học máy	Mục 1.2 Chương 1: Định dạng chuẩn Mitchell (T, E, P), xác định đúng bài toán phân cụm không giám sát, đơn vị mẫu 98 mã VN100, đầu vào ma trận Mantegna 98×98, đầu ra nhãn cụm.	1,0	1,0
2	Mục tiêu và tiêu chí thành công	Mục 1.3 Chương 1, Bảng 1.1: Bảng mục tiêu – chỉ số đầy đủ mức tham chiếu: Silhouette ≥ 0.25, CCC ≥ 0.70, ARI ≥ 0.40, Sharpe ≥ 1.0, MDD.	1,0	1,0
3	Nguồn và mô tả dữ liệu	Mục 2.1 & 2.2 Chương 2: Nguồn API vnstock/TCBS, điều kiện phi thương mại, 1.187 phiên, 98 mã, Bảng 2.1 từ điển 8 đặc trưng tài chính, metadata 11 ngành ICB.	1,0	1,0
4	Khảo sát thống kê và phân bố	Mục 2.3, 2.4, 2.5 Chương 2: Thống kê mô tả đầy đủ, Hình 2.1, 2.2, 2.3; kiểm định Jarque-Bera $p < 0.001$, Kurtosis = 3.86 (đuôi béo), nhận xét sâu sắc cho từng biểu đồ.	1,0	1,0
5	Phân tích quan hệ đặc trưng	Mục 2.6 Chương 2, Hình 2.4, 2.5: Ma trận Pearson và Mantegna; rút ra 4 nhận xét cốt lõi về hiệu ứng thị trường, liên kết ngành và tính chất mêtric.	1,0	1,0
6	Phát hiện vấn đề chất lượng dữ liệu	Mục 3.1 Chương 3, Bảng 3.1: Định lượng chi tiết: 2 mã thiếu niên yết (VTP, NAB), 68 ngày nghỉ lễ sàn HOSE, 48 ô khuyết rải rác và rủi ro Look-ahead bias.	1,0	1,0

(Tiếp theo Bảng 5.3)

TC	Tiêu chí đánh giá	Minh chứng cụ thể trong báo cáo và hệ thống mã nguồn	Điểm tối đa	Nhóm tự chấm
7	Xử lý vấn đề chất lượng dữ liệu	Mục 3.2 & 3.3 Chương 3, Bảng 3.2: Lọc 2 mã, bỏ ngày lễ, điền khuyết Forward-fill có lý do chặt chẽ; bảng so sánh trước (1.255×100) và sau (1.187×98).	1,0	1,0
8	Chuẩn bị dữ liệu cho mô hình	Mục 3.4, 3.5, 3.6 Chương 3: Lợi suất loga-rit trích chọn; chia Train (2022–2024: 62.3%) / Test (2025–2026: 37.7%) theo thời gian; ma trận tương quan và khoảng cách chỉ fit trên tập Train.	1,0	1,0
9	Lựa chọn và lý giải phương pháp	Mục 1.4 & 1.5 Chương 1: Lý giải chọn Hold-out chuỗi thời gian thay vì K-Fold; cơ sở lý thuyết RMT ($Q = 7.54 \gg 1$); lý giải các chỉ số Sil-houette, CCC, ARI, Sharpe, MDD.	1,0	1,0
10	Vấn đáp và thực hành cá nhân	Phụ lục A: Hướng dẫn cấu trúc notebook thực nghiệm; mã nguồn chuẩn mực, độc lập đường dẫn, sẵn sàng chạy trực tiếp và trả lời vấn đáp tại chỗ.	1,0	1,0
TỔNG ĐIỂM TỰ ĐÁNH GIÁ MỐC 1			**10,0**	**10,0**

Bảng 5.4. Bảng tự đánh giá kết quả thực hiện Mốc 2 (Tuần 6)

TC	Tiêu chí đánh giá	Minh chứng cụ thể trong báo cáo và hệ thống mã nguồn	Điểm tối đa	Nhóm tự chấm
1	Lựa chọn thuật toán phù hợp	Mục 4.1 Chương 4, Bảng 4.1, Hình 4.1: So sánh khách quan các thuật toán phân cụm (K-Means phẳng vs Phân cấp chia dần DIANA vs Phân cấp gộp Bottom-Up); chứng minh tính tất định $ARI \equiv 1.0$ và bản chất gộp hạt nhân vi mô đồng ngành từ đáy.	1,0	1,0

(Tiếp theo Bảng 5.4)

TC	Tiêu chí đánh giá	Minh chứng cụ thể trong báo cáo và hệ thống mã nguồn	Điểm tối đa	Nhóm tự chấm
2	Mô hình cơ sở (Baseline)	Mục 4.2 Chương 4: Xây dựng 2 mô hình cơ sở rõ ràng (KMeans_PCA_5D nén 47.3% phương sai và KMeans_PCA_45D nén 80% phương sai theo RMT); có bảng so sánh định lượng đa chiều.	1,0	1,0
3	Quy trình huấn luyện	Mục 4.3 Chương 4: Tổ chức pipeline khép kín, fit ma trận tương quan và khoảng cách Mantegna thuần túy trên tập Train (739 phiên), cách ly tuyệt đối tập Test, cố định seed (random_state=42).	1,0	1,0
4	Cài đặt mô hình bằng Python	Mục 4.3 Chương 4 & Phụ lục A: Toàn bộ mã nguồn chạy được trơn tru trên Python 3.12, sử dụng đúng thư viện scipy, scikit-learn, tích hợp cơ chế tự động dò tìm PROJECT_ROOT độc lập đường dẫn.	1,0	1,0
5	Huấn luyện và kiểm thử đúng phương pháp	Mục 4.6 Chương 4, Bảng 4.3, Hình 4.4: Kiểm định bằng Block Sub-sampling $B = 30$ khối ngẫu nhiên trên tập Train; báo cáo đầy đủ giá trị trung bình và độ lệch chuẩn ($\Delta = +0.1398 \pm 0.0114$, Silhouette $= 0.0297 \pm 0.0033$).	1,0	1,0
6	Đánh giá bằng chỉ số phù hợp	Mục 4.4, 4.5, 4.6 Chương 4, Bảng 4.2, Hình 4.2, 4.3, 4.5, 4.6: Đánh giá đa chiều qua Cophenetic CCC, Silhouette, Δ, Entropy chuẩn, bảng chéo ICB, Clustermap, PCA 2D.	1,0	1,0
7	Phân tích kết quả dự đoán (Phân tích lỗi)	Mục 4.7 Chương 4, Bảng 4.4: Phân tích 6 mã ranh giới có Silhouette âm (TCB, SBT, CTD, VCB, VIX, SSB); bóc tách cặn kẽ nguyên nhân kinh tế và rủi ro dòng tiền giằng co.	1,0	1,0
8	Giải thích nguyên lý thuật toán	Mục 4.4 & 4.5 Chương 4: Trình bày hàm mục tiêu phương sai gia tăng Ward ESS, chứng minh toán học đẳng thức mặt cầu $\mathbb{S}^{T-1}$ ($d_E \equiv d_M$, sai số 3.77×10^{-15}); giải thích vai trò siêu tham số K và Linkage.	1,0	1,0

(Tiếp theo Bảng 5.4)

TC	Tiêu chí đánh giá	Minh chứng cụ thể trong báo cáo và hệ thống mã nguồn	Điểm tối đa	Nhóm tự chấm
9	Giải thích hoạt động của mô hình trên dữ liệu	Mục 4.1 & 4.6 Chương 4, Chương 5: Lý giải vì sao Ward vượt trội K-Means gấp 2 lần về Δ (nhận diện hạt nhân vi mô HSG-NKG, DCM-DPM, tránh bẫy nghịch lý tương quan và bẫy Singleton).	1,0	1,0
10	Thực hành cá nhân tại chỗ	Phụ lục A: Hướng dẫn cấu trúc hệ sinh thái 8 notebook thực nghiệm; sẵn sàng thao tác trực tiếp, đổi siêu tham số, đổi linkage và đọc đúng kết quả trong 10–15 phút vấn đáp.	1,0	1,0
TỔNG ĐIỂM TỰ ĐÁNH GIÁ MỐC 2			**10,0**	**10,0**

TÀI LIỆU THAM KHẢO

[1] H. Markowitz (1952), "Portfolio selection", *The Journal of Finance*, vol. 7, no. 1, pp. 77–91.

[2] T. M. Mitchell (1997), *Machine Learning*, McGraw-Hill, New York.

[3] R. N. Mantegna (1999), "Hierarchical structure in financial markets", *The European Physical Journal B - Condensed Matter and Complex Systems*, vol. 11, no. 1, pp. 193–197.

[4] L. Laloux, P. Cizeau, J.-P. Bouchaud, M. Potters (1999), "Noise dressing of financial correlation matrices", *Physical Review Letters*, vol. 83, no. 8, pp. 1467–1470.

[5] J. MacQueen (1967), "Some methods for classification and analysis of multivariate observations", *Proceedings of the Fifth Berkeley Symposium on Mathematical Statistics and Probability*, vol. 1, no. 14, pp. 281–297.

[6] J. H. Ward Jr. (1963), "Hierarchical grouping to optimize an objective function", *Journal of the American Statistical Association*, vol. 58, no. 301, pp. 236–244.

[7] L. Kaufman, P. J. Rousseeuw (1990), *Finding Groups in Data: An Introduction to Cluster Analysis*, John Wiley & Sons, Hoboken, New Jersey.

[8] L. Hubert, P. Arabie (1985), "Comparing partitions", *Journal of Classification*, vol. 2, no. 1, pp. 193–218.

[9] N. X. Vinh, J. Epps, J. Bailey (2010), "Information theoretic measures for clusterings comparison: Variants, properties, normalization and correction for chance", *Journal of Machine Learning Research*, vol. 11, pp. 2837–2854.

[10] M. López de Prado (2016), "Building diversified portfolios that outperform out of sample", *The Journal of Portfolio Management*, vol. 42, no. 4, pp. 59–69.

[11] M. López de Prado (2018), *Advances in Financial Machine Learning*, John Wiley & Sons, Hoboken, New Jersey.

PHỤ LỤC A

HƯỚNG DẪN MÔI TRƯỜNG VÀ THỰC THI CÁC NOTEBOOK THỰC NGHIỆM

A.1. Yêu cầu môi trường phần mềm

Toàn bộ mã nguồn thực nghiệm của nhóm được viết trên nền tảng Python ≥ 3.10 (khuyến nghị Python 3.12). Các gói thư viện yêu cầu được liệt kê trong **requirements.txt**:

```
pip install numpy pandas scipy scikit−learn matplotlib seaborn vnstock
```

Kho lưu trữ mã nguồn dự án: https://github.com/courseprojectICTU/stock-clustering-portfolio-diversification

A.2. Cấu trúc hệ sinh thái 8 Notebook phục vụ kiểm tra vấn đáp tại chỗ (Tiêu chí 10)

Để phục vụ việc kiểm tra và thực hành trực tiếp tại chỗ theo yêu cầu của giảng viên, nhóm tổ chức hệ thống 8 notebook có thứ tự chạy tuần tự và độc lập, dữ liệu được đọc qua cơ chế PROJECT_ROOT:

1. **Sổ tay 01 (01_data_collection_prep.ipynb):** Thu thập dữ liệu thô 100 mã cổ phiếu rổ VN100 từ API **vnstock** và metadata phân ngành ICB. Lưu trữ dữ liệu thô tại **data/raw/**.
2. **Sổ tay 02 (02_data_preprocessing.ipynb):** Kiểm toán dữ liệu khuyết, loại bỏ 2 mã thiếu (**VTP**, **NAB**), nhận diện và loại bỏ 68 ngày nghỉ lễ sàn HOSE, áp dụng kỹ thuật Forward-fill xử lý 48 ô trống. Xuất bản ma trận giá sạch 1.187×98 tại data/processed/adj_close_clean.csv.
3. **Sổ tay 03 (03_feature_extraction_returns.ipynb):** Tính chuỗi lợi suất logarit (1.186×98), thực hiện kiểm định Jarque-Bera, tính độ nhọn Excess Kurtosis = 3.86 chứng minh hiện tượng đuôi béo (Fat-tails); trích chọn 8 đặc trưng tài chính định lượng.
4. **Sổ tay 04 (04_correlation_distance.ipynb):** Tính ma trận tương quan Pearson $\rho \in [-1, 1]$, chuyển đổi sang khoảng cách Mantegna $d = \sqrt{2(1-\rho)}$, chạy thuật

toán kiểm định bất đẳng thức tam giác trên 20.000 bộ ba.

5. **Sổ tay 05 (05_train_test_split.ipynb):** Phân chia tập dữ liệu In-Sample Train (2022–2024: 739 phiên lợi suất) và Out-of-Sample Test (2025–2026: 447 phiên lợi suất) theo lý thuyết RMT ($Q = 7.54$).
6. **Sổ tay 06 (06_algorithm_selection_hierarchical_vs_kmeans.ipynb):** Thực nghiệm đối chứng các thuật toán phân cụm (K-Means phẳng vs Phân cấp chia dần DIANA/Bisecting vs Phân cấp gộp Bottom-Up); chứng minh tính tất định $ARI \equiv 1.0$ và độ phân tách tương quan Δ.
7. **Sổ tay 07 (07_hierarchical_clustering_linkages.ipynb):** Thực nghiệm 4 tiêu chí liên kết (Single, Complete, Average, Ward), chứng minh đẳng thức mặt cầu $\mathbb{S}^{T-1}$, quét thực nghiệm $K \in [3, 15]$ chốt $K^* = 10$ bằng ma trận đa tiêu chí Composite Score, kiểm định Block Sub-sampling ($B = 30$) so với 2 Baseline, và phân tích lỗi mẫu ranh giới.
8. **Sổ tay 08 (08_stability_and_sector.ipynb):** Đánh giá độ ổn định liên pha qua 3 chu kỳ thị trường (2022 Downtrend, 2023 Tích lũy, 2024 Phục hồi) bằng ma trận ARI, và đối chiếu định lượng cấu trúc cụm với 11 phân ngành chuẩn ICB cấp 1 ($NMI = 0.5339$, Purity=60.20%).

A.3. Hướng dẫn chạy lại toàn bộ pipeline thực nghiệm

Người chấm có thể thực thi lại toàn bộ pipeline thực nghiệm và tái tạo lại toàn bộ hình ảnh, bảng biểu trong báo cáo chỉ bằng một dòng lệnh duy nhất tại thư mục gốc của dự án:

```
python scripts/export_report_figures.py
```

PHỤ LỤC B

NHẬT KÝ ĐÓNG GÓP CỦA CÁC THÀNH VIÊN TRONG NHÓM

Bảng B.1. Nhật ký công việc và đóng góp của các thành viên từ Tuần 1 đến Tuần 6

Tuần	Thời gian	Thành viên	Nội dung công việc và đóng góp
Tuần 1	05/10–11/10	Trần Phương Đoàn Hà Văn Dũng	Tìm hiểu đề tài, họp nhóm thống nhất định hướng phân cụm danh mục đầu tư; phát biểu bài toán theo chuẩn Mitchell (T, E, P).
Tuần 2	12/10–18/10	Trần Phương Đoàn	Xây dựng pipeline thu thập dữ liệu tự động 100 mã VN100 qua thư viện vnstock; lưu trữ dữ liệu thô tại data/raw/.
Tuần 2	12/10–18/10	Hà Văn Dũng	Thu thập metadata phân ngành ICB của 100 cổ phiếu; xây dựng từ điển dữ liệu tài chính phục vụ phân tích.
Tuần 3	19/10–25/10	Trần Phương Đoàn	Kiểm toán dữ liệu khuyết, phát hiện 2 mã thiếu (VTP, NAB) và 68 ngày nghỉ lễ sàn HOSE; thực hiện Forward-fill.
Tuần 3	19/10–25/10	Hà Văn Dũng	Tính toán chuỗi lợi suất logarit; kiểm định phân bố chuẩn Jarque-Bera; phân tích hiệu ứng đuôi béo (Fat-tails).
Tuần 4	26/10–30/10	Trần Phương Đoàn Hà Văn Dũng	Tính ma trận Pearson và khoảng cách mêtric Mantegna; chia tập Train/Test theo chu kỳ RMT; hoàn thiện Báo cáo Kiểm tra số 1.
Tuần 5	31/10–06/11	Trần Phương Đoàn	Cài đặt và thực nghiệm 4 tiêu chí liên kết trên ma trận Mantegna; đo hệ số Cophenetic CCC (nb07); vẽ biểu đồ Dendrogram.
Tuần 5	31/10–06/11	Hà Văn Dũng	Cài đặt và so sánh đối chứng các thuật toán phân cụm (K-Means, Bisecting, DIANA, Agglomerative) (nb06); xây dựng 2 Baseline PCA 5D/45D.
Tuần 6	07/11–13/11	Trần Phương Đoàn	Quét thực nghiệm $K \in [3, 15]$, thiết lập ma trận đa tiêu chí chốt $K^* = 10$ (nb07); đánh giá ổn định liên pha ARI và đối chiếu 11 ngành ICB (nb08).
Tuần 6	07/11–13/11	Hà Văn Dũng	Cài đặt kiểm định Block Sub-sampling ($B = 30$); phân tích mẫu ranh giới Silhouette âm (nb07); hoàn thiện Báo cáo Kiểm tra số 2.